

4 Variáveis aleatórias reais

É frequente estarmos interessados em associar aos resultados de uma experiência aleatória uma ou mais características numéricas.

Por exemplo, na experiência aleatória que consiste em efetuar dois lançamentos consecutivos de um dado equilibrado, podemos estar interessados em estudar:


- o número de faces par obtidas;
- a soma das faces obtidas;
- a diferença entre as faces obtidas;
- o valor máximo obtido nos 2 lançamentos;
- etc.

Se quisermos estudar apenas uma característica numérica, matematicamente isto é formalizado através de uma função que a cada elemento $\omega \in \Omega$ atribui um número real, *i.e.*, uma função

$$\begin{aligned} X : \Omega &\rightarrow \mathbb{R} \\ \omega &\mapsto X(\omega) \end{aligned}$$

em que Ω é o espaço de resultados da experiência. X é designada de **variável aleatória real** (v.a.r. ou simplesmente v.a.).

Exemplo: Suponhamos que estamos interessados em estudar o número de faces par obtidas em dois lançamentos consecutivos de um dado. Parte da função X é dada por:



O acontecimento "não sair qualquer face par" é definido como $\{\omega \in \Omega : X(\omega) \in \{0\}\} = X^{-1}(\{0\}) = \{(1,1), (1,3), (1,5), (3,1), (3,3), (3,5), (5,1), (5,3), (5,5)\}$. O acontecimento "sair pelo menos uma face par" é definido como $\{\omega \in \Omega : X(\omega) \in \{1,2\}\} = X^{-1}(\{1,2\})$.

Observações:

1. As variáveis aleatórias representam-se, geralmente, pelas últimas letras maiúsculas do alfabeto latino: $X, Y, Z, X_1, Y_1, Z_1, \dots$;
2. Um valor particular representa-se por uma letra minúscula;

3. $P(X = x) = P(X(\omega) = x) = P(\{\omega \in \Omega : X(\omega) = x\})$;
4. Num mesmo espaço de resultados podem definir-se diversas variáveis aleatórias.
5. Se quisermos estudar mais do que uma característica numérica, somos conduzidos a uma função vetorial:

$$\begin{aligned}\mathbf{X} : \Omega &\rightarrow \mathbb{R}^k \\ \omega &\mapsto (X_1(\omega), X_2(\omega), \dots, X_k(\omega))\end{aligned}$$

Neste caso, chamamos vetor aleatório de dimensão k . Notar que, todos os conceitos aplicados a uma variável aleatória que iremos falar de seguida existem, de forma equivalente, para vetores aleatórios.

Define-se **função de distribuição (cumulativa)** de uma v.a. X como a função real de valor real, $F_X : \mathbb{R} \rightarrow [0, 1]$, que para cada $x \in \mathbb{R}$ faz corresponder a probabilidade do acontecimento $\{\omega : X(\omega) \leq x\}$ e representa-se por:

$$F_X(x) = P(X \leq x).$$

Algumas **propriedades da função de distribuição**:

1. $0 \leq F_X(x) \leq 1, \forall x \in \mathbb{R}$;
2. F_X é não decrescente;
3. $P(x_0 < X \leq x_1) = F_X(x_1) - F_X(x_0)$, com $x_0 < x_1$.

Exemplo: Seja X o número de faces par obtidas nos dois lançamentos do dado. Qual a probabilidade de X ser menor do que 2?

$$P(X < 2) = P(X \leq 1) = F_X(1) = P(X = 0) + P(X = 1) = \frac{9}{36} + \frac{18}{36} = \frac{27}{36} = 0.75$$

E a probabilidade de ser menor ou igual a 2 e maior do que 0?

$$P(0 < X \leq 2) = F_X(2) - F_X(0) = 1 - P(X = 0) = 1 - \frac{9}{36} = 0.75$$

As variáveis aleatórias podem ser classificadas como:

- **discreta** se o conjunto dos seus possíveis valores for um conjunto finito ou infinito numerável;
- **contínua** se os seus valores possíveis constituem um intervalo ou uma união de intervalos reais.


Se Ω for finito ou numerável, então qualquer v.a. nele definida terá que ser discreta, pois o número de valores distintos do contradomínio não pode exceder o número de elementos de Ω . Já no caso de Ω ser infinito não numerável, as v.a. nele definidas podem ser discretas ou contínuas. Por exemplo, no tiro ao alvo, podemos estar interessados na pontuação do tiro, atribuída de acordo com a distância ao alvo (e.g., 20, 10, 5 ou 0). Neste caso, estamos perante uma variável discreta. Mas,

se o interesse for na distância exata ao alvo (medida, por exemplo, em cm), já estaremos perante uma variável contínua.

Exemplo: Consideremos a experiência aleatória que consiste na medição do tempo de funcionamento (tempo de vida), em horas, de uma componente eletrónica, com $\Omega = [0, +\infty[$. Definam-se as seguintes variáveis aleatórias:

- T: "v.a. que indica o tempo de vida (duração) da componente eletrónica"

Os valores possíveis desta v.a. coincidem com o espaço de resultados, tratando-se de uma variável contínua.




T v.a. contínua

- Z: "v.a. que indica se a duração é maior que 100h ou não"

$$Z = \begin{cases} 0, & T \leq 100 \\ 1, & T > 100 \end{cases}$$

Os valores possíveis desta v.a. são 0 e 1, logo é uma v.a. discreta.




Z v.a. discreta

- W: v.a. definida como:

$$W = \begin{cases} 0, & T \leq 100 \\ T - 100, & T > 100 \end{cases}$$

Os valores possíveis desta v.a. são 0 ou $\mathbb{R}^+$. Neste caso, esta variável diz-se **mista**. Trata-se de uma mistura entre variável discreta e contínua, em que existe uma massa de probabilidade concentrada num ponto e a restante probabilidade distribui-se continuamente num intervalo.



W v.a. mista

Outros exemplos deste tipo de variável são a quantidade de precipitação (l/m^2h) ou o tempo de espera de um veículo num semáforo. Em qualquer dos casos, existe uma massa de probabilidade p concentrada no ponto 0 (probabilidade de não chover ou probabilidade de o semáforo estar verde), *i.e.*, $P(X = 0) = p$, em que $0 < p < 1$, e a restante probabilidade $1 - p$ distribui-se continuamente no intervalo $]0, +\infty[$.

A noção de v.a.'s independentes decorre diretamente da noção de acontecimentos independentes. Podemos dizer, em geral, que duas variáveis aleatórias são **independentes** se para quaisquer $A \subseteq \mathbb{R}$ e $B \subseteq \mathbb{R}$, os acontecimentos $X \in A$ e $Y \in B$ são independentes, ou seja,

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B).$$

Suponhamos o caso de uma população com uma v.a. X em estudo (por exemplo, o peso numa dada população animal). Recolhendo ao caso, com reposição, uma amostra aleatória dessa população, as v.a.'s associadas a cada um dos elementos da amostra $X_1, X_2, \dots, X_n$, são independentes, e todas com a mesma distribuição (a distribuição de X), *i.e.*, são réplicas de X , independentes. Deste modo, uma amostra aleatória $X_1, X_2, \dots, X_n$ é o mesmo que n v.a.'s independentes e identicamente distribuídas (i.i.d.'s) com X . O caso da amostragem sem reposição é praticamente equivalente a este, desde que a dimensão N da população seja elevada e n seja pequeno relativamente a N .

Por exemplo, em 10 lançamentos (independentes) de um dado equilibrado, o resultado X_1 do primeiro lançamento e o resultado X_{10} do décimo lançamento são v.a.'s independentes. Em amostragem com reposição, podemos mesmo dizer que, nos mesmos 10 lançamentos, a soma de pintas nos primeiros 4 lançamentos e a soma de pintas nos últimos 2 lançamentos são independentes. No caso de amostragem sem reposição, não há, em geral, independência entre v.a.'s referentes a extrações distintas.

Quanto a tipos de amostragem envolvendo duas v.a.'s destacam-se os seguintes casos:

1. duas populações em estudo e duas amostras recolhidas ao acaso, independentemente uma da outra (as amostras podem ter tamanhos diferentes), *e.g.*, peso na população masculina e peso na população feminina. $\Rightarrow$ Duas **amostras independentes** uma das outra.
2. duas populações e duas amostras intencionalmente relacionadas (ambas com o mesmo tamanho), *e.g.* alturas de pares irmão/irmã em famílias escolhidas ao acaso. $\Rightarrow$ Duas **amostras emparelhadas**.
3. uma população e uma amostra de duas v.a.'s em estudo, eventualmente interligadas, *e.g.*, peso e altura numa população de homens. $\Rightarrow$ Duas **amostras emparelhadas**.

Estes tipos de amostragem são determinantes na escolha dos procedimentos estatísticos a aplicar em cada situação.

4.1 Variáveis aleatórias discretas

Seja X uma v.a. discreta assumindo valores em $R_X = \{x_1, x_2, \dots\}$. A **função (massa) de probabilidade** de X é dada por:

$$f_X(x) \equiv P(X = x) = \begin{cases} P(X = x_i), & x = x_i \in R_X \\ 0, & c.c. \end{cases}$$

e satisfaz:

- $P(X = x) \geq 0, \forall x \in \mathbb{R};$
- $\sum_{x \in \mathbb{R}} P(X = x) = \sum_{x \in R_X} P(X = x) = 1.$

Esta função pode ser denotada por $P(X = x)$, $P_X(x)$, $f_X(x)$ ou $f(x)$.

Uma v.a. discreta fica identificada pelo seu contradomínio, R_X , e pela função massa de probabilidade, que a cada elemento do contradomínio faz corresponder a sua probabilidade.

A função de probabilidade é a versão teórica, ou populacional, que tem a correspondente versão empírica, ou amostral, nas tabelas de frequências relativas e nos diagramas de linhas ou gráficos de barras estudados antes.

Exemplo 1: Consideremos novamente X o número de faces par obtidas nos dois lançamentos de um dado.

$$f_X(x) = P(X = x) = \begin{cases} 0.25, & \text{se } x = 0 \text{ ou } x = 2 \\ 0.5, & \text{se } x = 1 \\ 0, & c.c. \end{cases}$$



Exemplo 2: Consideremos o lançamento de duas moedas equilibradas, em que se observa o número de coroas. O espaço de resultados é dado por: $\Omega = \{(F, F), (C, F), (F, C), (C, C)\}$, onde F : "saída de Face" e C : "saída de Coroa".

Seja Y a v.a. "número de coroas obtidas no lançamento". Y é discreta e pode tomar os valores $y = 0, 1, 2$: $R_Y = \{0, 1, 2\}$.

$$P(Y = 0) = P(\{(F, F)\}) = \frac{1}{4}$$

$$P(Y = 1) = P(\{(C, F), (F, C)\}) = \frac{1}{2}$$

$$P(Y = 2) = P(\{(C, C)\}) = \frac{1}{4}$$

Logo, a função de probabilidade de Y é dada por:

$$f_Y(y) \equiv P(Y = y) = \begin{cases} 1/4, & y = 0, 2 \\ 1/2, & y = 1 \\ 0, & y \notin \{0, 1, 2\} \end{cases}.$$

A função de distribuição de uma v.a. discreta, X , é dada por:


$$F_X(x) = P(X \leq x) = \sum_{x_i \leq x} P(X = x_i), x \in \mathbb{R}$$

e é então uma função em "escada". Os "saltos" são o valor da função de probabilidade no ponto correspondente. O cálculo de probabilidades à custa de F_X é simples:

- $P(X = a) = F_X(a) - F_X(a^-)$
- $P(X > a) = 1 - F_X(a)$
- $P(a < X \leq b) = F_X(b) - F_X(a), a < b$
- $P(a \leq X < b) = F_X(b^-) - F_X(a^-), a < b$
- $P(X \in A) = \sum_{x_i \in A} P(X = x_i), \forall A \subseteq \mathbb{R}$

Exemplo: Considerando novamente o exemplo anterior do lançamento de duas moedas, a função de distribuição da v.a. Y é dada por:

$$F_Y(y) = \begin{cases} 0, & y < 0 \\ 1/4, & 0 \leq y < 1 \\ 1/4 + 1/2, & 1 \leq y < 2 \\ 1/4 + 1/2 + 1/4, & y \geq 2 \end{cases} = \begin{cases} 0, & y < 0 \\ 1/4, & 0 \leq y < 1 \\ 3/4, & 1 \leq y < 2 \\ 1, & y \geq 2 \end{cases}$$



Quer a função de distribuição quer a função de probabilidade caracterizam completamente uma v.a. discreta. No entanto, podemos estar interessados em outras medidas que caracterizem de forma parcial a v.a.. Entre essas medidas podem destacar-se:

- Medidas de localização:
 - Valor esperado;
 - Moda;
 - Mediana;
 - Quantis;
- Medidas de dispersão:
 - Variância;
 - Desvio padrão.

Todas estas características (ditas teóricas ou populacionais) têm as respetivas características amostrais, estudadas anteriormente.

O **valor esperado**, valor médio, ou média de uma v.a. discreta X , com função de probabilidade $f_X(x)$, representa-se por $E(X)$, μ_X ou μ , e é dado por:

$$E(X) = \sum_x x f_X(x).$$

Observações:

- $E(X)$ é um valor numérico nas mesmas unidades que a variável X , mas não é necessariamente um dos valores que a variável pode tomar.
- Quando X é uma v.a. discreta que tem um número infinito de valores, $E(X)$ existe se a série for absolutamente convergente.

Algumas **propriedades do valor esperado** de uma v.a.:

1. $E[h(X)] = \sum_x h(x)f_X(x)$, onde $h(\cdot)$ é uma função de X mensurável. (De notar que, em geral, $E[h(X)] \neq h(E[X])$, exceto nos casos em que h é uma função linear ou a v.a. é constante.)
2. $E(aX + b) = aE(X) + b$, $\forall a, b \in \mathbb{R}$

Exemplo: Considere novamente a v.a. Y que representa o número de coroas no lançamento de duas moedas equilibradas. Imagine que se paga um preço para lançar as duas moedas e se recebe um prémio de Y^2 Euros. Qual o preço justo a pagar?

Como o valor equilibrado do prémio a longo prazo é $E(Y^2)$, então o valor justo a pagar será de $E(Y^2)$ Euros. A função de probabilidade de Y^2 é dada por:

i	0	1	4
$P(Y^2 = i)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

então $E(Y^2) = 0 \times \frac{1}{4} + 1 \times \frac{1}{2} + 4 \times \frac{1}{4} = 1.5$ (Euros).

De notar que $E(Y^2) \neq [E(Y)]^2 = \left(0 \times \frac{1}{4} + 1 \times \frac{1}{2} + 2 \times \frac{1}{4}\right)^2 = 1$.

A **moda** de uma v.a. X discreta com função de probabilidade f_X representa-se por μ_o ou $mo(X)$ e é o valor ou valores onde a função probabilidade é máxima, ou seja:

$$f_X(\mu_o) = \max_x f_X(x)$$

ou equivalentemente:

$$\mu_o = \arg \max_x f_X(x).$$

A moda existe sempre, mas pode não ser única.

Exemplo: Considerando novamente a v.a. Y que representa o número de coroas no lançamento de duas moedas, temos que $mo(Y) = 1$, porque $P(Y = 1) = \frac{1}{2} > P(Y = y) = \frac{1}{4}, y = 0, 2$.

A **mediana** de uma v.a. X , com função de distribuição F_X , representa-se por μ_e ou $med(X)$ e é um ponto central em termos de probabilidade, ou seja, tal que, se possível,


$$P(X \leq \mu_e) = P(X \geq \mu_e)$$

i.e.,

$$\mu_e : P(X \leq \mu_e) \geq 0.5 \quad \text{e} \quad P(X \geq \mu_e) \geq 0.5$$

que é equivalente a:

$$\mu_e : 0.5 \leq F_X(\mu_e) \leq 0.5 + P(X = \mu_e).$$



Seja $p \in]0, 1[$. O **quantil de ordem (ou probabilidade) p** da variável aleatória X , com função de distribuição F_X , é todo o número real q_p tal que:

$$q_p : P(X \leq q_p) \geq p \quad \text{e} \quad P(X \geq q_p) \geq 1 - p$$

que é equivalente a:

$$q_p : p \leq F_X(q_p) \leq p + P(X = q_p).$$

A **variância** de uma v.a. discreta, com função de probabilidade f_X , e cujo valor esperado

$E(X) = \mu_X$ existe, representa-se por $V(X)$, $Var(X)$, σ_X^2 ou σ^2 , e é dada por:

$$V(X) = E[(X - \mu_X)^2] = \sum_x (x - \mu_X)^2 f_X(x).$$

Observações:

- A variância é um valor numérico expresso no quadrado das unidades da v.a. X .
- Assim como pode não existir valor esperado, também pode não existir variância.
- Como curiosidade, do mesmo modo que o valor esperado é análogo do conceito físico de centro de gravidade, $V(X)$ é análoga do momento de inércia em relação a um eixo que passa pelo centro de gravidade.

O **desvio padrão** de X , σ_X , é dado por $\sigma_X = +\sqrt{V(X)}$, sendo expresso nas unidades da variável.

Algumas **propriedades da variância** de uma v.a.:

1. $V(X) \geq 0, \forall X$;
2. $V(X) = E(X^2) - [E(X)]^2 = E(X^2) - E^2(X)$
3. $V(aX + b) = a^2 V(X), \forall a, b \in \mathbb{R}$ (A variância não é um operador linear!)
4. $V(X) = 0 \Leftrightarrow \exists c : P(X = c) = 1$, ou seja, X é constante com probabilidade 1 – também se diz "v.a. degenerada".

Exemplo: Considerem-se duas v.a. X e Y cujas funções de probabilidade são, respetivamente:

$$X: \begin{array}{c|ccc} x & -1 & 1 & \text{c.c.} \\ \hline f_X(x) & 1/2 & 1/2 & 0 \end{array} \quad Y: \begin{array}{c|ccc} y & -1000 & 1000 & \text{c.c.} \\ \hline f_Y(y) & 1/2 & 1/2 & 0 \end{array}$$

Pode-se verificar que $E(X) = E(Y) = 0$. No entanto:

$$E(X^2) = (-1)^2 \times \frac{1}{2} + 1^2 \times \frac{1}{2} = 1 \quad \text{e} \quad E(Y^2) = (-1000)^2 \times \frac{1}{2} + 1000^2 \times \frac{1}{2} = 1000^2$$

Logo, $V(X) = 1 - 0 = 1$ e $V(Y) = 1000^2 - 0 = 1000^2$, e $\sigma_X = 1$ e $\sigma_Y = 1000$.

4.1.1 Exemplos de distribuições de probabilidade discretas

Distribuição Bernoulli

Uma experiência aleatória chama-se **prova ou experiência de Bernoulli** quando só tem dois resultados possíveis, o sucesso (a ocorrência do acontecimento de interesse), A , ou insucesso (o seu complementar), $\bar{A}$. A partir de experiências de Bernoulli define-se uma variável aleatória X , com distribuição de Bernoulli, do seguinte modo:

$$\begin{aligned} X &= 1 \text{ se ocorre } A \\ X &= 0 \text{ se ocorre } \bar{A} \\ \text{com } R_X &= \{0, 1\}. \end{aligned}$$

A v.a. X discreta tem **distribuição de Bernoulli de parâmetro p** , $0 < p < 1$ (escreve-se, $X \sim \text{Bernoulli}(p)$ ou $X \sim \text{Ber}(p)$) quando

$$P(X = x) = \begin{cases} p, & x = 1 \\ 1 - p, & x = 0 \\ 0, & \text{c.c.} \end{cases} \equiv \begin{cases} p^x(1-p)^{1-x}, & x = 0, 1 \\ 0, & \text{c.c.} \end{cases}$$

onde $p = P(X = 1)$ é a probabilidade de sucesso.

$$E(X) = p \quad \text{e} \quad V(X) = p(1-p)$$

Exemplo: Considere-se uma caixa com N bolas, das quais:

M são brancas - característica associada ao "sucesso" (A)
 $(N - M)$ são pretas - característica associada ao "insucesso" ($\bar{A}$)

Considere-se a E.A. "Extrair 1 bola ao acaso" e X "v.a. que indica a ocorrência de sucesso (bola branca)". Então,

$$X \sim \text{Bernoulli}\left(p = \frac{M}{N}\right).$$

Admitindo que a caixa tem 100 bolas, das quais 20 são brancas, então $N = 100$, $M = 20$, $N - M = 80$ e $X \sim \text{Bernoulli}(0.2)$. Neste caso, $P(X = 1) = 0.2$ corresponde à probabilidade de sair uma bola branca e $P(X = 0) = 1 - 0.2 = 0.8$ corresponde à probabilidade de sair uma bola preta. O parâmetro p pode ser entendido como a proporção de bolas brancas na caixa.

Distribuição Binomial

Numa população em que uma dada proporção p ($0 < p < 1$) dos seus elementos tem uma certa característica A , e os restantes elementos não têm essa característica, podemos efetuar n extrações com reposição (ou seja, extrair uma amostra aleatória de dimensão n), e considerar a v.a. X que representa o número de elementos da amostra que têm a característica A . Como neste caso estamos perante extrações independentes (uma vez que a amostragem é realizada com reposição), há $\binom{n}{x}$ maneiras distintas de extrair exatamente x elementos com a característica A , cada uma delas com probabilidade $p^x(1-p)^{n-x}$ de ocorrer.

A v.a. X discreta que indica o número de sucessos observados em n realizações independentes de provas de Bernoulli e com probabilidade de sucesso p em cada prova, diz-se ter **distribuição Binomial de parâmetros $n \in \mathbb{N}$ e $p \in]0, 1[$** (escreve-se $X \sim \text{Binomial}(n, p)$ ou $X \sim \text{Bin}(n, p)$) e tem função de probabilidade igual a:

$$P(X = x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x}, & x = 0, 1, 2, \dots, n \\ 0, & \text{c.c.} \end{cases}$$

onde $\binom{n}{x} = C_x^n = \frac{n!}{(n-x)!x!}$.

$$E(X) = np \quad \text{e} \quad V(X) = np(1 - p)$$

Observe-se que, se $X \sim \text{Binomial}(1, p)$, então $X \sim \text{Bernoulli}(p)$.

Em R, para $X \sim \text{Binomial}(n, p)$, temos que:

comando*	cálculo efetuado
<code>dbinom(x,n,p)</code>	$P(X = x)$
<code>pbinom(x,n,p)</code>	$P(X \leq x)$
<code>pbinom(x,n,p,lower.tail=FALSE)</code>	$P(X > x)$
<code>qbinom(pp,n,p)</code>	quantil de probabilidade pp
<code>rbinom(r,n,p)</code>	amostra simulada, de dimensão r

*Os prefixos *d*, *p*, *q* e *r* podem ser utilizados com outras distribuições definidas em R, devendo apenas ser feitos os devidos ajustes: *binom* deve ser substituído pela distribuição pretendida e os argumentos deverão ser ajustados aos necessários para a definição da distribuição. (Outros exemplos da aplicação destes comandos disponíveis ao longo do capítulo.)

Exemplo 1: Considere-se novamente a caixa com N bolas, das quais M são brancas e $(N - M)$ são pretas. Considere-se agora a E.A. "Extraír n bolas ao acaso e com reposição". Como a extração é feita com reposição, então estamos perante n provas de Bernoulli independentes.

Seja X "v.a. que indica o número de sucessos (n° de bolas brancas) nas n bolas". Como $P(\text{"sucesso"}) = \frac{M}{N} = p$, então:

$$X \sim \text{Binomial}\left(n, p = \frac{M}{N}\right)$$

Admitindo que a caixa tem 100 bolas, das quais 20 são brancas, e que são feitas 3 extrações com reposição, então $X \sim \text{Binomial}(3, 0.2)$.

Qual a probabilidade de o n° de bolas brancas ser no máximo 1?

$$P(X \leq 1) = F_X(1) = 0.896 \text{ (consultando a tabela)}$$

```
pbinom(1, 3, 0.2) # 0.896
```

Exemplo 2: Numa população muito grande, sabe-se que 50% das pessoas são a favor de jogos eletrónicos. Se forem seleccionadas 10 pessoas, ao acaso, qual é a probabilidade de encontrar 6 que são a favor de jogos eletrónicos? E qual é a probabilidade de encontrar pelo menos 6 nas mesmas condições?

Seja X a v.a. que indica o " n° de pessoas a favor de jogos eletrónicos nas 10 seleccionadas ao acaso". X representa o n° de sucessos em 10 provas de Bernoulli que se podem considerar independentes dado que a população é muito grande, com $p = 0.5$. Logo, $X \sim \text{Binomial}(10, 0.5)$. Então a probabilidade de encontrar 6 pessoas que são a favor de jogos eletrónicos é dada por:

$$P(X = 6) = \binom{10}{6} \times 0.5^6 \times (1 - 0.5)^{10-6} = \frac{105}{512} \approx 0.2050781$$

```
dbinom(6, 10, 0.5) # 0.2050781
```

Uma terceira alternativa para efetuar o cálculo será pelo uso das tabelas:

$$P(X = 6) = F_X(6) - F_X(5) = 0.8281 - 0.6230 = 0.2051.$$

A probabilidade de encontrar pelo menos 6 pessoas que são a favor de jogos eletrônicos é dada por:

$$P(X \geq 6) = \sum_{x=6}^{10} \binom{10}{x} \times 0.5^{10} = \dots = 1 - P(X < 6) = 1 - P(X \leq 5) = 1 - F_X(5)$$

```
1-pbinom(5,10,0.5) # 0.3769531
pbinom(5,10,0.5,lower.tail=FALSE) #P(X>5) = 0.3769531
```

Pelas tabelas, obtém-se

$$P(X \geq 6) = 1 - F_X(5) = 1 - 0.6230 = 0.3770.$$


```
#Função de probabilidade
plot(x=0:10,dbinom(0:10,10,0.5),type="h",col="darkorchid4",xlab="",ylab=
      "P(X=x)",main="Função de probabilidade de Bin(10,0.5)")

#Função Distribuição desenhada por segmentos
plot(NA, xlim = c(-0.5, 10), ylim = c(-0.1, 1.1), xlab = "", ylab =
      expression(P(X<=x)),main="Função distribuição Bin(10,0.5)")

segments(-1, 0, 0, 0, col = "darkorchid4", lwd = 3)
x_pts <- rep(0:10, each=2)[-1]
y_pts <- rep(pbinom(0:10,10,0.5), each=2)[-22]
for (i in seq(1, length(x_pts), 2)){
  segments(x_pts[i], y_pts[i], x_pts[i+1], y_pts[i+1], col = "
    darkorchid4", lwd = 3)
}

# Bolinhas Abertas
points(c(0, x_pts[ seq(2, length(x_pts), 2) ]), c(0, y_pts[ seq(2,
  length(x_pts), 2) ]), pch = 21, bg = "white", col = "darkorchid4",
  cex = 1.3, lwd = 1.5)

# Bolinhas Fechadas
points(x_pts[ seq(1, length(x_pts), 2) ], y_pts[ seq(1, length(x_pts),
  2)], pch = 19, col = "darkorchid4", cex = 1.3)
```



O modelo binomial é um caso particular do modelo multinomial. No modelo binomial, os dados são classificados numa de 2 classes (a classe dos que têm a característica em causa, e a classe dos que não têm). Esta classificação pode ser generalizada para várias classes (mutuamente exclusivas e exaustivas). Por exemplo, numa amostra de uma população humana, podemos classificar os seus elementos quanto à idade em 4 classes etárias (e.g., crianças, jovens, adultos e idosos), e teremos então uma distribuição multinomial associada a esta amostra. Esta distribuição é essencial nos métodos estatísticos que lidam com dados classificados ou categorizados.

Distribuição Geométrica

Seja X a v.a. que indica o n° de provas de Bernoulli independentes e com probabilidade de sucesso constante (p), realizadas até à obtenção do primeiro sucesso (inclusive). Diz-se que X tem **distribuição geométrica de parâmetro p** , $0 < p < 1$ (escreve-se $X \sim \text{Geométrica}(p)$ ou $X \sim \text{Geom}(p)$) e tem função de probabilidade igual a:

$$P(X = x) = \begin{cases} (1-p)^{x-1}p, & x = 1, 2, 3, \dots \\ 0, & \text{c.c.} \end{cases}$$

$$E(X) = \frac{1}{p} \quad \text{e} \quad V(X) = \frac{1-p}{p^2}$$

A distribuição geométrica tem a propriedade da **falta de memória** ou **amnésia**:

$$P(X > i + j | X > j) = P(X > i), \quad \forall i, j = 1, 2, \dots$$

A distribuição geométrica pode também ser definida como o número de insucessos antes do primeiro sucesso. Neste caso, $Y = X - 1$ e Y tem suporte em $\{0, 1, 2, \dots\}$ com $P(Y = y) = (1-p)^y p$. Esta é a implementação que se encontra disponível no R.

Exemplo 1: Considere-se novamente o exemplo da caixa com 100 bolas, das quais 20 são brancas e as restantes pretas. Qual é a probabilidade de ser necessário extrair (com reposição) no mínimo 3 bolas até encontrar a 1ª branca?

Seja X a v.a. que indica o número de insucessos até ao 1º sucesso (bola branca), então $X \sim \text{Geométrica}(0.2)$.

$$P(X \geq 3) = 1 - F_X(2) = 1 - \sum_{k=1}^2 P(X = k) = 1 - \left((1 - 0.2)^{1-1} \times 0.2 + (1 - 0.2)^{2-1} \times 0.2 \right) = 0.64$$

Para o cálculo em R, é necessário utilizar a v.a. $Y = X - 1$, ou seja,

$$P(X \geq 3) = P(Y \geq 2) = 1 - F_Y(1).$$

```
1-pgeom(1,0.2) #0.64
pgeom(1,0.2,lower.tail = FALSE) #P(Y>1)=0.64
```

Exemplo 2: Seja X a v.a. que indica o número de lançamentos de um dado equilibrado até surgir a primeira face 3. Qual o número esperado de lançamentos do dado até sair a face 3?

$$X \sim \text{Geométrica}(1/6)$$

logo,

$$E(X) = 6.$$

Qual a probabilidade de serem necessários mais de 10 lançamentos, sabendo que já houve 7 lançamentos do dado sem que a face 3 saísse?

$$\begin{aligned} P(X > 10 | X > 7) &\stackrel{\text{amnésia}}{=} P(X > 3) = 1 - P(X \leq 3) \\ &= 1 - F_X(3) \\ &= 1 - [P(X = 1) + P(X = 2) + P(X = 3)] \\ &= 1 - \left[(1/6) + (5/6) \times (1/6) + (5/6)^2 \times (1/6) \right] \end{aligned}$$

Usando $Y = X - 1$, $P(X \leq 3) = P(Y \leq 2)$:

```
1-pgeom(2,1/6) #0.5787037
```

4.2 Variáveis aleatórias contínuas

Seja X uma v.a. e F_X a sua função de distribuição. A v.a. X diz-se contínua se F_X for absolutamente contínua, i.e., se e só se existe uma função **não negativa**, $f_X : \mathbb{R} \rightarrow \mathbb{R}_0^+$, tal que, para todo o $x \in \mathbb{R}$ se tem:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt$$

À função f_X chama-se **função de densidade de probabilidade** (f.d.p.), ou apenas função de densidade.

A função densidade f_X da v.a. contínua X satisfaz:

$$1. \int_{-\infty}^{+\infty} f_X(x) dx = 1$$

$$2. f_X(x) = \frac{d}{dx} F_X(x)$$

Observações:

- O método usado para descrever as v.a.'s discretas (lista dos valores possíveis de X e respectivas probabilidades) não é aplicável a v.a.'s contínuas, pois é impossível elaborar uma lista de todos os valores possíveis de uma v.a. contínua (infinitos não numeráveis).
- O termo densidade lembra a "quantidade de massa por unidade de comprimento, de superfície ou de volume". Neste caso, podemos dizer que f_X indica a probabilidade por unidade de comprimento "na vizinhança do ponto x ".


A **função de distribuição** de uma v.a. contínua X é dada por:

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t)dt, \quad \text{com } x \in \mathbb{R}$$

A função distribuição de uma v.a. X contínua é uma função contínua, ao contrário da f.d. de uma v.a. discreta, que é uma função em "escada".

A função densidade de probabilidade de uma v.a. contínua X pode ser utilizada para o cálculo de algumas probabilidades:


- $P(X = x) = \int_x^x f_X(t)dt = 0, \quad \forall x \in \mathbb{R}$
- $P(a \leq X \leq b) = \int_a^b f_X(x)dx, \quad \forall a, b \in \mathbb{R} : a \leq b$
- $P(a \leq X \leq b) = P(a \leq X < b) = P(a < X \leq b) = P(a < X < b) = \int_a^b f_X(x)dx = F_X(b) - F_X(a), \quad \forall a, b \in \mathbb{R} : a \leq b$



Exemplo: Considere uma v.a. X que indica o tempo de vida (em milhares de horas) de uma componente eletrônica, que tem a seguinte função densidade de probabilidade:

$$f(x) = \begin{cases} \frac{e^{-\frac{x}{5}}}{5}, & x \geq 0, \\ 0, & c.c. \end{cases}$$

```
plot(NA, xlab = "x", ylab = expression(f[X](x)),
ylim = c(0, 0.3), xlim = c(0,30))
curve(exp(-x/5)/5,0,30,add=TRUE,col="skyblue",lwd=2)
```




Para determinar a função de distribuição de X , temos que:

$$x < 0: \quad F_X(x) = \int_{-\infty}^x 0 dt = 0$$

$$x \geq 0: \quad F_X(x) = \int_{-\infty}^0 0 dt + \int_0^x \frac{e^{-t/5}}{5} dt = - \left[e^{-t/5} \right]_0^x = 1 - e^{-x/5}$$

$$F_X(x) = \begin{cases} 0, & x \leq 0 \\ 1 - e^{-x/5}, & x > 0 \end{cases}$$

```
plot(NA, xlab = "x", ylab = expression(F[X](x)), ylim = c(0, 1), xlim =
      c(0,30))
curve(1-exp(-x/5), 0,30,add=TRUE,col="skyblue",lwd=2)
abline(h = 1, col = "gray60", lwd = 1, lty = 2)
```



Qual a probabilidade de o tempo de vida ser superior a 70 milhares de horas, sabendo que é superior a 60 milhares de horas?

$$\begin{aligned} P(X > 70 | X > 60) &= \frac{P(X > 70 \wedge X > 60)}{P(X > 60)} = \frac{P(X > 70)}{P(X > 60)} \\ &= \frac{1 - P(X \leq 70)}{1 - P(X \leq 60)} = \frac{1 - F_X(70)}{1 - F_X(60)} \\ &= \frac{e^{-70/5}}{e^{-60/5}} = e^{-2} = P(X > 10) \end{aligned}$$

Nota: A v.a. X deste exemplo tem uma **distribuição exponencial de parâmetro λ** , $\lambda > 0$ (neste caso, $\lambda = 1/5$). A propriedade que aqui acabámos de verificar no cálculo da probabilidade acima é designada de propriedade da **falta de memória** ou **amnésia**. A distribuição exponencial é a única

distribuição contínua sem memória, tal como a distribuição geométrica é a única distribuição discreta sem memória. O facto de esta distribuição não ter memória significa que não é indicada para modelar situações do tipo tempo de vida em que há desgaste ou envelhecimento.

Tal como nas variáveis aleatórias discretas, quer a função de distribuição quer a função de densidade caracterizam completamente uma v.a. contínua. No entanto, também neste caso podemos estar interessados noutras medidas que caracterizam de forma parcial a v.a.: valor esperado, moda, mediana, quantis, variância e desvio padrão. De seguida, apresentam-se as alterações que é necessário efetuar ao cálculo destas medidas quando a v.a. é contínua relativamente ao seu cálculo para uma v.a. discreta.

▪ **Valor esperado:**

$$E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx$$

$$E[h(X)] = \int_{-\infty}^{+\infty} h(x) f_X(x) dx, \text{ onde } h(\cdot) \text{ é uma função mensurável.}$$

▪ **Moda:** mantém-se a mesma forma de cálculo

$$f_X(\mu_o) = \max_x f_X(x) \text{ ou equivalente } \mu_o = \arg \max_x f_X(x).$$

De notar que, numa v.a. contínua, é frequente ter de se falar em classe modal, em vez de moda.

▪ **Mediana:** mantém-se a mesma forma de cálculo, mas é possível reduzi-la a $F_X(\mu_e) = 0.5$.

▪ **Quantil de ordem (ou probabilidade) p :** tal como na mediana, mantém-se a mesma forma de cálculo, mas é possível reduzi-la a $F_X(q_p) = p$.

▪ **Variância:**

$$V(X) = E[(X - \mu_X)^2] = \int_{-\infty}^{+\infty} (x - \mu_X)^2 f_X(x) dx$$

▪ **Desvio padrão:** mantém-se a mesma forma de cálculo $\sigma_X = +\sqrt{V(X)}$.

As **propriedades do valor esperado e da variância** enunciadas para as v.a.'s discretas mantêm-se válidas no caso de uma v.a. contínua.

Exemplo: A procura diária de arroz num supermercado, em centenas de quilos, é uma variável aleatória com função densidade de probabilidade:

$$f_X(x) = \begin{cases} (2x)/3, & 0 \leq x < 1 \\ -x/3 + 1, & 1 \leq x \leq 3 \\ 0, & \text{outros valores de } x \end{cases}$$

Calculemos o valor esperado e a variância da procura diária de arroz.

$$\begin{aligned}
E(X) &= \int_{-\infty}^{+\infty} x f_X(x) dx \\
&= \int_0^1 x(2x)/3 dx + \int_1^3 x(-x/3 + 1) dx \\
&= \int_0^1 \frac{2x^2}{3} dx + \int_1^3 \left(-\frac{x^2}{3} + x \right) dx \\
&= \left[\frac{2x^3}{9} \right]_0^1 + \left[-\frac{x^3}{9} + \frac{x^2}{2} \right]_1^3 \\
&= \frac{4}{3} \text{ (em centenas de kg)}
\end{aligned}$$

$\sigma_X^2 \equiv V(X) = E(X^2) - E^2(X)$, logo precisamos de calcular $E(X^2)$.

$$\begin{aligned}
E(X^2) &= \int_{-\infty}^{+\infty} x^2 f_X(x) dx \\
&= \int_0^1 x^2(2x)/3 dx + \int_1^3 x^2(-x/3 + 1) dx \\
&= \int_0^1 \frac{2x^3}{3} dx + \int_1^3 \left(-\frac{x^3}{3} + x^2 \right) dx \\
&= \left[\frac{2x^4}{12} \right]_0^1 + \left[-\frac{x^4}{12} + \frac{x^3}{3} \right]_1^3 \\
&= \frac{13}{6}
\end{aligned}$$

Assim, $V(X) = \frac{13}{6} - \left(\frac{4}{3}\right)^2 = \frac{7}{18}$ (em centenas de kg)².

4.2.1 Exemplos de distribuições de probabilidade contínuas


Distribuição Normal (ou Gaussiana)

A distribuição normal apareceu pela primeira vez (embora sem nome) num trabalho de De Moivre em 1733, como um "limite" da distribuição binomial quando $n \rightarrow \infty$. Este resultado permaneceu praticamente desconhecido durante os 80 anos seguintes, até que, em 1812, Laplace o generalizou e publicou, sendo este resultado conhecido como Teorema de De Moivre-Laplace.

```

par(mfrow = c(1,3))
for (n in c(50,100,500)){
  for (p in c(0.2,0.5,0.9)){
    hist(rbinom(1000, n, p), probability = TRUE, ylab = "Frequência
      relativa", xlab = "x", main = paste("Binomial(",n,",",p,")"), col
      = "mistyrose")
    curve(dnorm(x, n*p, sqrt(n*p*(1-p))), 0, n, add = TRUE, col = "
      orchid4", lwd = 3)
  }
}

```



Independentemente, esta distribuição foi estudada por Gauss (1809) e utilizada para modelar erros de medição em astronomia.

O termo "distribuição normal" (típica, habitual) só apareceu muito mais tarde (cerca de 1875). Esta distribuição é também conhecida como distribuição Gaussiana, ou de Gauss, ou ainda de Laplace-Gauss.


A distribuição normal é uma boa aproximação para muitos fenómenos naturais (físicos, biológicos, psicológicos,...) e não só (económicos, sociais, ...). Além disso, é fundamental em estatística indutiva.

Uma v.a. contínua X tem **distribuição normal de parâmetros μ e σ^2** , com $\mu \in \mathbb{R}$ e $\sigma > 0$, e escreve-se $X \sim N(\mu, \sigma^2)$ ou $X \sim \text{Normal}(\mu, \sigma^2)$, se a sua f.d.p. é da forma

$$f_X(x) = f_X(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad \forall x \in \mathbb{R}$$

$$E(X) = \mu \quad \text{e} \quad V(X) = \sigma^2$$

```
plot(NA, xlab = "x", ylab = expression(f[X](x)), ylim = c(0, 1), xlim =
  c(-5,5))
curve(dnorm(x,3,1), -5, 5, add = TRUE, col = "skyblue", lwd = 2)
curve(dnorm(x,0,0.5), -5, 5, add = TRUE, col = "darkorchid4", lwd = 2)
curve(dnorm(x,0,2), -5, 5, add = TRUE, col = "orange", lwd = 2)
curve(dnorm(x,0,1), -5, 5, add = TRUE, col = "darkgreen", lwd = 2)
legend("topleft", legend = c("N(3,1)", "N(0,0.25)", "N(0,4)", "N(0,1)"),
  col = c("skyblue", "darkorchid4", "orange", "darkgreen"), lty=1, lwd=2)
```



Algumas **propriedades da distribuição normal**:

- Se $X \sim N(\mu, \sigma^2)$ e $Y = aX + b$, em que a e b são constantes com $a \neq 0$, então $Y \sim N(a\mu + b, a^2\sigma^2)$.

■

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

Trata-se de um caso particular da alínea anterior, quando $a = \frac{1}{\sigma}$ e $b = -\frac{\mu}{\sigma}$. À distribuição $N(0, 1)$ chama-se **Normal padrão/padronizada**, **Normal standard** ou **Normal reduzida**.

- Pela alínea anterior, é possível transformar qualquer variável aleatória normal numa normal padrão (basta subtrair o valor esperado e dividir pelo desvio padrão). Esta propriedade permite o cálculo de qualquer probabilidade de uma distribuição normal à custa apenas da distribuição normal padrão:

$$F_X(x) = P(X \leq x) = P\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) = P\left(Z \leq \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

onde $\Phi(z) \equiv P(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$ é a **função de distribuição da normal padrão**, i.e., $Z \sim N(0, 1)$.

O integral acima não é possível de calcular de forma analítica, uma vez que não tem primitiva elementar. Deste modo, não é possível obter uma expressão para a função de distribuição e os

cálculos das probabilidades associadas a uma distribuição normal têm de ser efetuados por métodos numéricos (ou mudança de variável para $\mathbb{R}^2$):

- computador ou calculadora (não é necessário usar a normal padrão);
- tabelas (é necessário usar a normal padrão). Neste caso, está também tabelada a função de distribuição inversa da normal padrão, $\Phi^{-1}(p)$, $p \in [0, 1]$, ou seja, a tabela que permite o cálculo dos **quantis da distribuição normal padrão**.

Propriedades da função de distribuição da normal padrão, devidas à simetria da f.d.p.:

- $\Phi(-x) = 1 - \Phi(x)$, $\forall x \in \mathbb{R}$
- $P(a < X < b) = P\left(\frac{a - \mu}{\sigma} < \frac{X - \mu}{\sigma} < \frac{b - \mu}{\sigma}\right) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$
- $\Phi^{-1}(p) = -\Phi^{-1}(1 - p)$, $\forall p \in [0, 1]$

Exemplo: Uma empresa fabrica um tipo de lâmpada cuja duração média é de 300 dias, com um desvio padrão de 50 dias. O engenheiro responsável pelo departamento de qualidade acredita que a vida útil daquelas lâmpadas é normalmente distribuída. Para decidir qual a duração que deve ser anunciada como garantida, ele pretende calcular os seguintes valores:

1. a probabilidade de uma lâmpada ter uma vida útil superior a um ano;

Seja X : "tempo de vida útil de uma lâmpada deste tipo (em dias)". Então, $X \sim N(300, 50^2)$.

$$\begin{aligned}
 P(X > 365) &= 1 - P(X \leq 365) \\
 &= 1 - P\left(\frac{X - \mu}{\sigma} \leq \frac{365 - \mu}{\sigma}\right) \\
 &= 1 - P\left(Z \leq \frac{365 - 300}{50}\right) \\
 &= 1 - \Phi\left(\frac{365 - 300}{50}\right) \\
 &= 1 - \Phi(1.3) \\
 &\stackrel{\text{tabela}}{=} 1 - 0.9032 \\
 &= 0.0968
 \end{aligned}$$

```
pnorm(365, mean = 300, sd = 50, lower.tail = FALSE) # 0.09680048
1-pnorm(365, mean = 300, sd = 50) # 0.09680048
```


```
#Representação gráfica da probabilidade
set.seed(123)
hist(rnorm(1000,300,50), xlab = "x", probability = TRUE, ylab = "
  Densidade", ylim = c(0, 0.01), main = "Normal(300,50)", col = "
  mistyrose")
curve(dnorm(x,300,50), 100, 500, col = "darkorchid4", lwd = 3, add
  = TRUE)
```

```

x_area <- seq(365, 500, length.out = 500)
y_area <- dnorm(x_area, 300, 50)

polygon(c(365, x_area, 500),
c(0, y_area, 0),
col = "darkorchid",
density = 30,
angle = 30,
border = "darkorchid")

```



A probabilidade calculada antes, $P(X > 365)$, corresponde à área sombreada a roxo no gráfico. Esta corresponde, de forma aproximada, à área do histograma construído com base numa amostra simulada, ou seja, à frequência relativa de observações maiores do que 365.

2. o tempo de vida útil que é excedido por 95% daquelas lâmpadas.

Queremos saber o tempo de vida útil t cuja probabilidade de a vida útil ser superior a t é igual a 0.95.

$$\begin{aligned}
 P(X > t) = 0.95 &\Leftrightarrow 1 - P(X \leq t) = 0.95 \\
 &\Leftrightarrow 1 - P\left(\frac{X - \mu}{\sigma} \leq \frac{t - \mu}{\sigma}\right) = 0.95 \\
 &\Leftrightarrow 1 - \Phi\left(\frac{t - \mu}{\sigma}\right) = 0.95 \\
 &\Leftrightarrow \Phi\left(\frac{t - \mu}{\sigma}\right) = 1 - 0.95 \\
 &\Leftrightarrow \Phi\left(\frac{t - 300}{50}\right) = 0.05 \text{ (quantil de probabilidade 0.05)} \\
 &\Leftrightarrow \frac{t - 300}{50} = \Phi^{-1}(0.05) \\
 &\Leftrightarrow t = 50 \times \Phi^{-1}(0.05) + 300
 \end{aligned}$$

Como calcular $\Phi^{-1}(0.05)$ com recurso às tabelas existentes?

```


curve(dnorm(x,0,1), -4, 4, col = "darkorchid4", lwd = 3, xlab = "x"
      , ylab = "Densidade", main = "Normal padrão", xaxt = "n", bty =
      "n")
axis(1, at = c(qnorm(0.05),0, qnorm(0.95)), labels = c(expression(
  paste(Phi^{-1}, "(0.05)")), "0", expression(paste(Phi^{-1}, "
  (0.95)"))))

x_area_esq <- seq(-4, qnorm(0.05), length.out = 500)
y_area_esq <- dnorm(x_area_esq, 0, 1)
polygon(c(-4, x_area_esq, qnorm(0.05)),
  c(0, y_area_esq, 0), col = "darkorchid", density = 10, angle = 30,
  border = "darkorchid")

x_area_dir <- seq(qnorm(0.95), 4, length.out = 500)
y_area_dir <- dnorm(x_area_dir, 0, 1)
polygon(c(qnorm(0.95), x_area_dir, 4),
  c(0, y_area_dir, 0), col = "darkorchid", density = 10, angle = 30,
  border = "darkorchid")
text(x = c(-3,1.8), y = c(0.05,0.05), labels = c("0.05","0.05"),
  pos = 4,col="darkorchid4",cex=1.2)

x_area_95 <- seq(-4, qnorm(0.95), length.out = 500)
y_area_95 <- dnorm(x_area_95, 0, 1)
polygon(c(-4, x_area_95, qnorm(0.95)), c(0, y_area_95, 0), col = "
  darkgreen", density = 10, angle = -30, border = "darkgreen")
text(x = -0.5, y = 0.2, labels = "0.95", pos = 4,col="darkgreen",cex
  =1.2)

```



$$\Phi^{-1}(0.05) = -\Phi^{-1}(1 - 0.05) = -\Phi^{-1}(0.95)$$

$$\begin{aligned}
 P(X > t) = 0.95 &\Leftrightarrow t = 50 \times \Phi^{-1}(0.05) + 300 \\
 &\Leftrightarrow t = 50 \times (-\Phi^{-1}(1 - 0.05)) + 300 \\
 &\Leftrightarrow t \stackrel{\text{tabela}}{=} 50 \times (-1.6449) + 300 \\
 &\Leftrightarrow t = 217.755 \text{ (dias)}
 \end{aligned}$$


```

set.seed(123)
hist(rnorm(1000,300,50), xlab = "x", probability = TRUE, ylab = "
  Densidade", ylim = c(0, 0.01), main = "Normal(300,50)", col = "
  mistyrose")
curve(dnorm(x,300,50), 100, 500, col = "darkorchid4", lwd = 3, add
  = TRUE)

x_area_pro <- seq(217.8, 500, length.out = 500)
y_area_pro <- dnorm(x_area_pro, 300, 50)

polygon(c(217.8, x_area_pro, 500),
  c(0, y_area_pro, 0), col = "darkorchid", density = 30, angle = 30,
  border = "darkorchid")

```




A área sombreada a roxo no gráfico acima representa a probabilidade de 95%, pelo que o extremo inferior do sombreado representa o tempo de vida útil que é excedido por 95% das lâmpadas. Por outro lado, este valor é o quantil de probabilidade 5% de X (não é da normal padrão).

Um processo visual rápido para avaliar se uma dada amostra $x_1, x_2, \dots, x_n$ provém do modelo normal $N(\mu, \sigma^2)$ consiste em elaborar um gráfico quantil-quantil amostral (comando `qqnorm` no R). De forma geral, se a amostra provier do modelo normal, espera-se que os quantis amostrais (recorde-se que são calculados a partir da amostra ordenada, sendo $x_{(i)} = q_{\frac{i-1}{n-1}}$) sejam aproximadamente iguais aos quantis teóricos desse modelo. Deste modo, os pontos $(\Phi^{-1}(p_i), x_{(i)})$ deverão apresentar-se aproximadamente em linha reta, em que p_i pode ser dado por $\frac{i-1}{n-1}$ (no caso do modelo normal é usual tomar-se $p_i = \frac{i-3/8}{n+1/4}$).

No entanto, deve salientar-se que este método é empírico e subjetivo, sendo além disso pouco fiável no caso de n ser pequeno. Segue-se, como exemplo, um gráfico `qqnorm` dos dados das erupções

superiores a 3 minutos (com dimensão 175), retiradas da amostra `faithful`. Os pontos apresentam uma certa curvatura, suscitando dúvidas quanto à normalidade dos dados. A reta representada é a reta que passa pelo 1º e 3º quartis.

```
attach(faithful)
er_grandes <- eruptions[eruptions>3]
length(er_grandes) # 175
qqnorm(er_grandes, las = 1, main = "Gráfico qqnorm", xlab = "Quantis
      normais", ylab = "Amostra ordenada")
qqline(er_grandes)
```



De lembrar que, para que um modelo de regressão linear simples seja útil e válido, tal como falado anteriormente (2.3 e 2.4), os resíduos têm de apresentar algumas características: comportamento normal, média 0, simetria, aleatoriedade e variância constante. Na verdade, estas características vêm de se assumir que os erros de um modelo de regressão linear simples seguem uma distribuição normal $N(0, \sigma^2)$. Na avaliação da qualidade do ajustamento, um dos gráficos que se obtém em R é exatamente o gráfico quantil-quantil amostral, tal como consta em 2.4.

4.3 Teorema do Limite Central

Imagine que o elevador de acesso à galeria de uma mina tem capacidade nominal de 3800kg. Admitindo que é conhecida a distribuição da variável que representa o peso de cada mineiro que usa o elevador, como poderia ser calculada a probabilidade de ser excedida a capacidade nominal do elevador quando nele se encontram 50 mineiros?

Se X_i for a v.a. que representa o peso do i -ésimo mineiro (em kg), então estaremos interessados em calcular $P\left(\sum_{i=1}^{50} X_i > 3800\right)$. Mas como saber a distribuição de $\sum_{i=1}^{50} X_i$?

Na maioria das situações é difícil determinar a distribuição da soma de variáveis, mesmo que sejam independentes. O teorema do limite central vem justificar a grande utilidade e importância da distribuição normal (quer em probabilidades quer em estatística). Este teorema diz-nos que, para um grande número de v.a.'s com idêntico comportamento (distribucional), seja ele qual for, e mesmo que seja praticamente desconhecido, a distribuição da soma das v.a.'s aproxima-se de uma distribuição normal, e tem uma distribuição que é tão mais próxima da normal, quanto maior for o número de v.a.'s da soma.

Teorema do Limite Central (TLC): Seja $X_1, \dots, X_n$ uma sequência de v.a.'s **independentes** e **identicamente distribuídas** com valor esperado $\mu < \infty$ e variância $\sigma^2 < \infty$. Considere-se $S_n = \sum_{i=1}^n X_i$ e $\bar{X}_n = \frac{S_n}{n}$. Então, quando $n \rightarrow +\infty$,

$$\frac{S_n - E(S_n)}{\sqrt{V(S_n)}} = \frac{S_n - n\mu}{\sqrt{n\sigma^2}} \stackrel{a}{\sim} N(0, 1).$$

e, de modo equivalente,

$$\frac{\bar{X}_n - E(\bar{X}_n)}{\sqrt{V(\bar{X}_n)}} = \frac{\bar{X}_n - \mu}{\sqrt{\sigma^2/n}} \stackrel{a}{\sim} N(0, 1).$$

Observações:

- As v.a.'s $X_1, \dots, X_n$ podem ser discretas ou contínuas.
- Geralmente considera-se n grande se $n \geq 30$.
- A utilização do teorema do limite central para distribuições discretas apresenta um problema, uma vez que se vai aproximar um fenómeno discreto por uma distribuição contínua. Fica a nota que, embora não exista uma solução ótima para todas as situações, na prática é comum adotar a chamada correção de continuidade. Aqui, não iremos considerar a correção de continuidade.
- No caso de $X_i \sim N(\mu, \sigma^2)$, $\forall i \in \{1, \dots, n\}$, então os resultados do TLC são exatos, ou seja, $\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \sim N(0, 1)$ e $\frac{\bar{X}_n - \mu}{\sqrt{\sigma^2/n}} \sim N(0, 1)$. Este é um caso particular de uma propriedade mais geral da distribuição normal: se $X_i \sim N(\mu_i, \sigma_i^2)$ forem v.a.'s independentes, então

$$\sum_{i=1}^n a_i X_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right).$$

Exemplo: Uma empresa de chocolates embala caixas com 100 pacotes de bombons. Os pesos por pacote são v.a.'s X_i , onde $X_i \perp\!\!\!\perp X_j$, com valor médio 0.5kg e variância 0.1kg². São colocadas 10 caixas numa paleta. Qual é a probabilidade aproximada do peso dos bombons da paleta ser superior a 510kg?

Seja X_i a v.a. que representa o peso do i -ésimo pacote (kg). Temos que $E(X_i) = 0.5$, $V(X_i) = 0.1$ e $X_i \perp\!\!\!\perp X_j$, para $i \neq j$.

Consideremos $S = \sum_{i=1}^{1000} X_i$ a v.a. do peso dos bombons colocados na paleta (em kg). Então,

$$E(S) = E\left(\sum_{i=1}^{1000} X_i\right) = \sum_{i=1}^{1000} E(X_i) = 1000E(X_1) = 1000 \times 0.5 = 500$$

$$V(S) = V\left(\sum_{i=1}^{1000} X_i\right) = \sum_{i=1}^{1000} V(X_i) = 1000V(X_1) = 1000 \times 0.1 = 100$$

porque as v.a.'s X_i são independentes e identicamente distribuídas a X_1 .

Pelo TLC, tem-se que:

$$\frac{S - E(S)}{\sqrt{V(S)}} = \frac{S - 500}{\sqrt{100}} \stackrel{a}{\sim} N(0, 1)$$

$$P(S > 510) = 1 - P(S \leq 510) = 1 - P\left(\frac{S - 500}{\sqrt{100}} \leq \frac{510 - 500}{\sqrt{100}}\right) \stackrel{\text{TLC}}{\approx} 1 - \Phi(1) \stackrel{\text{tabela}}{=} 0.1587$$