

5 Inferência Estatística

A **Inferência Estatística** integra um amplo conjunto de métodos que têm por objetivo usar a informação constante nos dados (amostra) de modo a responder a questões específicas sobre a população. A Inferência Estatística parte do particular (amostra) para o geral (população).

População: conjunto de todas as observações possíveis de determinada variável de interesse, X

Amostra: subconjunto de valores da população. Tem de ser selecionada de forma aleatória e deve ser representativa da população de onde foi retirada.

Amostra aleatória de dimensão n de X : $(X_1, \dots, X_n)$ em que cada $X_i \stackrel{d}{=} X$, $i = 1, \dots, n$ e X_i e X_j são independentes $\forall i, j$, $i \neq j$.

Porque é necessário utilizar amostras? Para conhecer exatamente X teríamos de fazer um número muito grande ou infinito de observações, o que pode ser impossível, pois a população pode ser muito grande, pode ser muito caro e/ou muito demorado, ou pode até levar à extinção da população X .

Pode-se admitir dois níveis de desconhecimento sobre a população X :

- $F_X(x)$ é completamente desconhecida, sabendo-se apenas se é do tipo contínuo ou discreto;
- Admite-se (pelo conhecimento do fenómeno em causa) que $F_X(x)$ pertence a determinada família, ou seja, segue uma determinada distribuição de probabilidade, mas com parâmetros desconhecidos.

Assim, a Inferência Estatística pode ter dois objetivos:

- estimar $F_X(x)$ ou estimar os parâmetros de $F_X(x)$ conhecendo a sua forma;
- fazer testes em relação aos parâmetros ou em relação à forma de $F_X(x)$.

5.1 Estimação pontual de parâmetros

Considerando uma amostra aleatória (a.a.) $(X_1, X_2, \dots, X_n)$ proveniente de uma população com determinada lei de probabilidade da qual se desconhece apenas o valor do parâmetro θ , a estimação paramétrica procura responder à seguinte questão: como utilizar a informação dada pela amostra para estimar o valor desconhecido de θ ?

Em geral, usa-se funções da amostra, que não envolvam parâmetros desconhecidos, para estimar certos aspetos da população, i.e., define-se uma **estatística** (v.a. que é função unicamente da amostra aleatória e que não depende de parâmetros desconhecidos) com o objetivo de encontrar um bom estimador para o parâmetro desconhecido.

Exemplos de estatísticas:

	Estatística	Valor observado da estatística
Mínimo amostral	$X_{(1)} = \min\{X_1, \dots, X_n\}$	$x_{(1)} = \min\{x_1, \dots, x_n\}$
Máximo amostral	$X_{(n)} = \max\{X_1, \dots, X_n\}$	$x_{(n)} = \max\{x_1, \dots, x_n\}$
Média amostral	$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
Variância amostral	$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
2º momento empírico	$M_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$	$m_2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \hat{\sigma}^2$ (variância populacional)

Observações:

- $S_n^2 \simeq M_2$ quando $n \rightarrow +\infty$
- $s^2 \simeq m_2$ quando n é suficientemente grande

Espaço de parâmetros Θ : é o conjunto de todos os valores possíveis para θ (parâmetro desconhecido a estimar).

Um **estimador** é uma estatística que só toma valores no espaço de parâmetros Θ , sendo uma variável aleatória com determinada lei de probabilidade.

Uma **estimativa** é uma concretização do estimador dado um conjunto de dados.

Observação: Existem vários estimadores para um só parâmetro.

Exemplo: Seja X a população que corresponde ao número de caras observado no lançamento de uma moeda não equilibrada. O modelo é conhecido, $X \sim \text{Bernoulli}(p)$, ($0 < p < 1$). O objetivo da amostragem será obter informação sobre p . Considere-se:

$$\begin{aligned} X = 1 & \quad \text{cara} & P(X = 1) &= p \\ X = 0 & \quad \text{coroa} & P(X = 0) &= 1 - p \end{aligned}$$

Observando uma amostra de dimensão 10 do lançamento desta moeda:

$$0 \quad 1 \quad 1 \quad 0 \quad 1 \quad 1 \quad 0 \quad 0 \quad 0 \quad 1$$

pode-se calcular qual é a probabilidade de observar aquela amostra em particular:

$$\begin{aligned} & P(X_1 = 0, X_2 = 1, X_3 = 1, X_4 = 0, X_5 = 1, X_6 = 1, X_7 = 0, X_8 = 0, X_9 = 0, X_{10} = 1) \\ &= P(X_1 = 0)P(X_2 = 1)P(X_3 = 1) \dots P(X_9 = 0)P(X_{10} = 1) \quad \text{porque as variáveis são independentes} \\ &= (1-p) \times p \times p \times (1-p) \times p \times p \times (1-p) \times (1-p) \times (1-p) \times p \\ &= p^5 \times (1-p)^5 \end{aligned}$$

O objetivo será estimar o parâmetro p .

Como $X_i = 1$ se ocorrer um sucesso e $X_i = 0$ se ocorrer um insucesso, conclui-se que $\sum_{i=1}^{10} X_i$ representa o número de sucessos na amostra aleatória e $\sum_{i=1}^{10} x_i$ é o número de sucessos na amostra concreta. Assim, de forma geral, o estimador do parâmetro p de uma população $X \sim \text{Bernoulli}(p)$ pode ser dado por:

$$\hat{p} = \bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

No caso da amostra observada, $\hat{p} = \bar{x} = \frac{5}{10} = 0.5$ é uma estimativa do parâmetro p .

Sendo as estatísticas variáveis aleatórias, têm uma distribuição associada. A essa distribuição designa-se distribuição por amostragem. Em alguns casos, é fácil saber a distribuição por amostragem. Por exemplo, de acordo com o teorema do limite central, quando $n \rightarrow +\infty$

$$\frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \underset{a}{\sim} N(0, 1)$$

sem que haja qualquer restrição para a lei de X a não ser $E(X^2) < \infty$.

5.1.1 Como encontrar estimadores?

Existem vários métodos de estimação pontual de parâmetros desconhecidos. Os dois métodos mais conhecidos são: método dos momentos e método da máxima verosimilhança. De seguida, descreve-se a ideia de cada um dos métodos e alguns dos estimadores obtidos para alguns dos parâmetros mais utilizados. Não iremos aprofundar nenhum dos métodos, ficando aqui apenas para conhecimento a ideia por trás de cada um deles.

1. Método dos momentos

Para encontrar estimadores de $\theta_1, \theta_2, \dots, \theta_k$, parâmetros desconhecidos de uma população X com momento de ordem k finito, basta igualar os k primeiros momentos teóricos aos k primeiros momentos empíricos e resolver o sistema de equações.

Momento de ordem k teórico: $E(X^k)$

Momento de ordem k empírico: $\frac{1}{n} \sum_{i=1}^n X_i^k$

Alguns estimadores obtidos pelo método dos momentos

População	Parâmetro	Estimador
$X \sim \text{Bernoulli}(p)$	p	$\hat{p} = \bar{X}$
$X \sim N(\mu, \sigma^2)$	μ	$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$
$X \sim N(\mu, \sigma^2)$	σ^2	$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

Observação: Pelo método dos momentos, a variância populacional, σ^2 , é estimada pelo 2º momento central amostral (variância amostral não corrigida) e não pela variância amostral.

2. Método de máxima verosimilhança

Tal como o nome indica, a estimativa de máxima verosimilhança obtém-se maximizando uma função chamada função de verosimilhança (*likelihood function*, em inglês). A ideia deste método centra-se no facto de o parâmetro θ ser desconhecido, mas $x_1, x_2, \dots, x_n$ serem conhecidos (são os nossos dados). Então a melhor aproximação para θ é o valor de θ que maximiza a probabilidade (ou densidade) de observar a amostra que efetivamente foi obtida. Por outras palavras, esse é o valor de θ mais compatível com os dados observados.

Seja X uma população com distribuição caracterizada por $f(x)$ conhecida a menos do parâmetro θ . Seja $(x_1, x_2, \dots, x_n)$ uma a.a. retirada de X .

A função de verosimilhança da amostra concreta $(x_1, \dots, x_n)$ é dada por

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i; \theta)$$

O estimador de máxima verosimilhança para θ , $\hat{\theta}$, é obtido por maximização de $L(\theta)$ ou $\ln(L(\theta))$. [Note que $\ln$ é uma função monótona (estritamente crescente)].

Observação: O estimador de máxima verosimilhança pode não ser único.

Alguns estimadores obtidos pelo método da máxima verosimilhança

População	Parâmetro	Estimador
$X \sim \text{Bernoulli}(p)$	p	$\hat{p} = \frac{\sum_{i=1}^n X_i}{n} = \bar{X}$
$X \sim N(\mu, \sigma^2)$	μ	$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$
$X \sim N(\mu, \sigma^2)$	σ^2	$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
$X \sim \text{Exp}(\lambda)$	λ	$\hat{\lambda} = \frac{1}{\bar{X}}$

Os estimadores de máxima verosimilhança têm a propriedade da invariância que diz que: se $\hat{\theta}$ é o estimador de máxima verosimilhança de um parâmetro θ , então $g(\hat{\theta})$ é o estimador de máxima verosimilhança de $g(\theta)$.

Exemplo: Seja $X_1, X_2, \dots, X_n$ uma a.a. proveniente de uma população X com distribuição Exponencial de parâmetro λ , que representa o tempo de vida (em centenas de dias) de uma componente eletrônica. Considere que se observou a seguinte amostra de dimensão 10:

0.1 1.0 0.5 2.1 1.3 1.9 2.5 2.2 3.5 2.3

Determine uma estimativa para $P(X > 2)$.

Pelo método de máxima verosimilhança, sabe-se que $\hat{\lambda} = \frac{1}{\bar{X}}$. Como (ver exemplo da distribuição exponencial no capítulo 4):

$$P(X > 2) = 1 - P(X \leq 2) = 1 - F_X(2) = 1 - (1 - e^{-\lambda \times 2}),$$

pela propriedade da invariância dos estimadores de máxima verosimilhança, vem que:

$$P(\widehat{X} > 2) = e^{-2\hat{\lambda}} = e^{-2\frac{1}{\bar{X}}}.$$

Assim, $\bar{x} = \frac{17.4}{10} = 1.74$ e $P(\widehat{X} > 2) = e^{-2\frac{1}{1.74}} = 0.3168$.

5.1.2 Propriedades dos estimadores

Nem sempre os métodos de estimação de parâmetros resultam no mesmo estimador para um parâmetro θ . Além disso, é possível que alguns métodos resultem em diversos estimadores para um mesmo parâmetro. Assim, existem vários critérios que especificam o que se entende por um "bom estimador pontual" do parâmetro θ . Nos próximos parágrafos, são descritos de forma genérica alguns destes critérios. Não fazendo parte dos objetivos da disciplina que os alunos sejam capazes de fazer os cálculos subjacentes a estes critérios, deverão ser capazes de entender os mesmos e, em caso de necessidade, ser capazes de identificar qual o melhor estimador pontual.

Em geral, se T é um estimador de θ , é desejável que T seja um **estimador centrado** (ou não enviesado), i.e., que o seu valor médio $E(T)$ coincida com θ (chama-se viés à distância entre estas duas quantidades, ou seja, $|E(T) - \theta|$). Se a dimensão da amostra n for suficientemente grande, bastará exigir que o **estimador seja assintoticamente centrado**, i.e., que o seu valor médio convirja (quando $n \rightarrow \infty$) para θ . Também é importante que um estimador (centrado)

tenha uma variância pequena, pois a sua distribuição estará mais concentrada em torno de θ (diz-se então que é mais **eficiente** que outro estimador centrado). No caso de T não ser centrado, uma medida usual da proximidade de T em relação a θ é dada pelo erro quadrático médio, definido por $E((T - \theta)^2)$. É possível provar que este é igual à soma da variância com o quadrado do viés, i.e., que $E((T - \theta)^2) = V(T) + (E(T) - \theta)^2$. Repare-se que se T for centrado, então o erro quadrático médio coincide com $V(T)$. Pode-se então dizer que, dados dois estimadores de θ , é melhor aquele que tiver menor erro quadrático médio. Nalguns modelos paramétricos, é possível encontrar um estimador do parâmetro, centrado e com variância mínima (i.e., com variância inferior à de qualquer outro estimador centrado desse parâmetro). Também é importante que T seja **consistente**, i.e., que convirja em probabilidade para θ , ou seja, que a probabilidade de T estar próximo de θ convirja para 1. De salientar que, se T é um estimador centrado, ou assintoticamente centrado, e se a sua variância $V(T)$ convergir para 0, então T é consistente.

Por exemplo, no caso de uma a.a. proveniente de um modelo $N(\mu, 1)$, podemos sugerir vários estimadores naturais para μ : a média amostral, a mediana amostral e a moda amostral (uma vez que, neste modelo, o parâmetro μ coincide com o valor médio, a mediana e a moda populacionais). No entanto, a média amostral é o "melhor" estimador centrado que existe para μ , no sentido em que pode provar-se que não há outro estimador centrado que tenha menor variância que este. Além disso, a média amostral é um estimador consistente, pois é centrado e a sua variância, $V(\bar{X}) = \sigma^2/n = 1/n$ converge para 0, quando $n \rightarrow \infty$.

No modelo $N(\mu, \sigma^2)$, pode provar-se que $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ é um estimador consistente de σ^2 , uma vez que é centrado e a variância tende para 0. Já o estimador da variância obtido pelo método dos momentos ou de máxima verosimilhança (segundo momento central amostral), apesar de ser um estimador consistente, não é centrado (na verdade, é assintoticamente centrado: $E(\hat{\sigma}) = \frac{n-1}{n} \sigma^2$), daí que não seja utilizado para estimar a variância. Mais geralmente, em qualquer modelo, S^2 é um estimador consistente da variância σ^2 .

Em geral, os estimadores obtidos pelo método dos momentos são:

- consistentes;
- têm distribuição assintótica normal;
- não são os assintoticamente mais eficientes, i.e., não asseguram variância assintótica mínima.


Já os estimadores obtidos pelo método da máxima verosimilhança são, em geral:

- enviesados;
- consistentes;
- têm distribuição assintótica normal;
- são assintoticamente mais eficientes;
- verificam a propriedade da invariância.

5.2 Estimação intervalar de parâmetros

Utilizar apenas um estimador pontual para um parâmetro provavelmente não irá permitir obter uma estimativa pontual que atinja o valor exato do parâmetro populacional (de relembrar que o objetivo da estimação de parâmetros é obter uma estimativa para a população com base na amostra). Uma estimativa pontual de um parâmetro não contém informação sobre a precisão que se pode depositar no valor obtido. Mas, se for calculada uma gama de valores plausíveis, então haverá uma boa chance de chegar ao parâmetro. Assim, uma forma mais completa de abordar a questão consiste em construir estimativas na forma de intervalos e conhecer a confiança do intervalo conter o verdadeiro valor do parâmetro. Ou seja, em vez de se propor apenas uma estimativa isolada $\hat{\theta}$ de θ faz-se acompanhar esta de um certo intervalo $]\theta_1, \theta_2[$. Em geral, o intervalo é da forma $]\hat{\theta} - \varepsilon, \hat{\theta} + \varepsilon[$, em que o valor de ε pode ser considerado uma medida de precisão da estimativa de θ , à qual é associada uma confiança de $(1 - \alpha) \times 100\%$. Assim, $\theta \in]\hat{\theta} - \varepsilon, \hat{\theta} + \varepsilon[$, com uma confiança de $(1 - \alpha) \times 100\%$. A confiança é fixada à partida e representa uma probabilidade. Por exemplo, para uma probabilidade fixada em 0.95, fala-se de um intervalo de 95% de confiança para o parâmetro em causa, sendo garantido que, em média, 95% dos intervalos calculados por aplicação do método conterão de facto o valor do parâmetro desconhecido. Diz-se também, por outras palavras, que este método tem uma margem de erro de 5%.

Um **intervalo aleatório de confiança** $1 - \alpha$ (IA ou IAC) é um intervalo do tipo $(T_1, T_2) =]T_1, T_2[$ onde T_1 e T_2 são estatísticas (v.a.'s) e tal que $P(\theta \in]T_1, T_2]) = 1 - \alpha$. Dada uma amostra particular, a concretização do intervalo aleatório de confiança $1 - \alpha$ designa-se por intervalo de confiança a $(1 - \alpha) \times 100\%$ (IC).



Dada uma a.a. $(X_1, X_2, \dots, X_n)$ proveniente da população X cuja distribuição de probabilidade depende do parâmetro desconhecido θ , uma **variável fulcral ou pivô** é uma função da a.a. $(X_1, X_2, \dots, X_n)$ e do parâmetro θ , cuja distribuição de probabilidade não depende de θ .

De forma geral, o procedimento para a obtenção de um intervalo de confiança para θ segue os seguintes passos:

1. **Definição da v.a. fulcral:** Seleção da variável fulcral Z (função de $(X_1, X_2, \dots, X_n)$ e do parâmetro θ);
2. **Obtenção dos quantis de probabilidade:** Fixado um grau de confiança, $1 - \alpha$, obtenção dos dois números a e b tais que:

$$P(a < Z < b) = 1 - \alpha$$

Como, em geral, existe uma infinidade de pares de valores (a, b) nessas condições, a opção mais comum consiste em escolher (a, b) tais que

$$P(Z < a) = P(Z > b) = \frac{\alpha}{2}$$

ou seja, a corresponde ao quantil de probabilidade $\frac{\alpha}{2}$ e b ao quantil de probabilidade $1 - \frac{\alpha}{2}$ da distribuição de Z .

3. **Inversão da desigualdade:** Resolver a desigualdade $a < Z < b$ para θ , ou seja, reorganizar a desigualdade de modo a obter:

$$P(a < Z < b) = P(T_1 < \theta < T_2) = 1 - \alpha$$

Obtém-se assim o IAC a $(1 - \alpha) \times 100\%$ para θ , (T_1, T_2) .

4. **Concretização:** Dada uma amostra particular, $(x_1, x_2, \dots, x_n)$, calcular (t_1, t_2) , que corresponde ao IC a $(1 - \alpha) \times 100\%$ para θ .

Interpretação do grau de confiança num IC

Se tivermos um número elevado de concretizações da a.a. $(X_1, \dots, X_n)$ retirada de X , a frequência relativa associada ao número de vezes que o verdadeiro valor do parâmetro pertence ao IC (intervalo de números reais) é $1 - \alpha$. Atenção que:

$$1 - \alpha \neq P(t_1 < \theta < t_2) = \begin{cases} 1 & \text{se } \theta \in (t_1, t_2) \\ 0 & \text{caso contrário} \end{cases},$$

ou seja, a probabilidade do parâmetro θ pertencer ao intervalo de confiança (t_1, t_2) é igual a 0 ou 1, mas a probabilidade do parâmetro θ pertencer ao intervalo aleatório de confiança (T_1, T_2) é igual a $1 - \alpha$.

Dedução de intervalos aleatórios

Na tabela seguinte, encontram-se as variáveis fulcrais e respetivos IA's para quatro principais situações. De seguida, apresenta-se o procedimento para a obtenção desses mesmos IA's a partir da variável fulcral.

Situação	Estimador pontual	Variável aleatória fulcral	Intervalo Aleatório
1. IC para a média de uma população normal, variância conhecida, $X \sim N(\mu, \sigma^2)$ *	$\hat{\mu} = \bar{X}$	$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$	$\left] \bar{X} - z \frac{\sigma}{\sqrt{n}}, \bar{X} + z \frac{\sigma}{\sqrt{n}} \right]$, onde $z = \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)$. Em R, <code>z.test</code> na <i>library</i> BSDA
2. IC para a média de uma população normal, variância desconhecida, $X \sim N(\mu, \sigma^2)$	$\hat{\mu} = \bar{X}$	$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{(n-1)}$	$\left] \bar{X} - t \frac{S}{\sqrt{n}}, \bar{X} + t \frac{S}{\sqrt{n}} \right]$, onde $t = F_{t_{(n-1)}}^{-1}\left(1 - \frac{\alpha}{2}\right)$. Em R, <code>t.test</code>
3. IC para a variância de uma população normal (valor médio desconhecido), $X \sim N(\mu, \sigma^2)$	$\hat{\sigma}^2 = S^2$	$Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$	$\left] \frac{(n-1)S^2}{b}, \frac{(n-1)S^2}{a} \right]$, onde $a = F_{\chi_{n-1}^2}^{-1}\left(\frac{\alpha}{2}\right)$ e $b = F_{\chi_{n-1}^2}^{-1}\left(1 - \frac{\alpha}{2}\right)$
4. IC para uma proporção, $X \sim \text{Bernoulli}(p)$ **	$\hat{p} = \bar{X}$	$Z = \frac{\bar{X} - p}{\sqrt{\frac{\bar{X}(1-\bar{X})}{n}}} \stackrel{a}{\sim} N(0, 1)$	$\left] \bar{X} - z \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}, \bar{X} + z \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \right]$, onde $z = \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)$. Em R, <code>prop.test</code> (aproximado) ou <code>binom.test</code> (exato).

* O intervalo aleatório obtido na situação 1, para o valor médio com a variância conhecida, pode também ser utilizado para uma população não normal, se a dimensão da amostra for grande e se se estiver em condições de aplicar o Teorema do Limite Central. De relembrar que este teorema garante a normalidade assintótica de $\bar{X}$. Os restantes intervalos apresentados não são aplicáveis em caso de não normalidade, uma vez que as distribuições por amostragem correspondentes já não são as mesmas que no modelo normal.

** Os intervalos de confiança dados pelas funções de R para uma proporção p não correspondem ao intervalo aleatório apresentado. Ver explicação e diferenças no ponto 4 abaixo.

Situação 1. IC para a média de uma população normal, variância conhecida

Considere-se uma população $X \sim N(\mu, \sigma^2)$, com σ^2 conhecida e μ o parâmetro a estimar. Seja $(X_1, \dots, X_n)$ uma a.a. de X de dimensão n . Sabe-se que $\hat{\mu} = \bar{X}$. Além disso, sabe-se também que

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$


A v.a. Z é função da a.a. (através de $\bar{X}$) e o único parâmetro desconhecido é o parâmetro a estimar μ (já que assumimos que σ^2 é conhecida). Além disso, tem distribuição conhecida ($N(0, 1)$) que não depende de μ . Logo, cumpre com os requisitos para ser uma v.a. fulcral e pode ser utilizada para construir um IC para μ .

Considerando uma confiança de $(1 - \alpha) \times 100\%$, pretende-se determinar a e b tais que


$$P\left(a < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < b\right) = 1 - \alpha$$

onde $1 - \alpha \approx 1$, ou seja, $\alpha \approx 0$.

Pela figura abaixo, pode notar-se que a amplitude $(b - a)$ é mínima quando $b = -a$, ou seja, quando se considera um intervalo simétrico em torno de zero.



$$\begin{aligned} P(a < Z < b) &= 1 - \alpha \\ \Leftrightarrow P\left(a < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < b\right) &= 1 - \alpha \\ \Leftrightarrow P\left(a \times \frac{\sigma}{\sqrt{n}} < \bar{X} - \mu < b \times \frac{\sigma}{\sqrt{n}}\right) &= 1 - \alpha \\ \Leftrightarrow P\left(a \frac{\sigma}{\sqrt{n}} - \bar{X} < -\mu < b \frac{\sigma}{\sqrt{n}} - \bar{X}\right) &= 1 - \alpha \\ \Leftrightarrow P\left(\underbrace{\bar{X} - b \frac{\sigma}{\sqrt{n}}}_{T_1} < \mu < \underbrace{\bar{X} - a \frac{\sigma}{\sqrt{n}}}_{T_2}\right) &= 1 - \alpha \end{aligned}$$



Considerando $z = \Phi^{-1}(1 - \frac{\alpha}{2})$,

$$\begin{aligned} IA_{(1-\alpha) \times 100\%}(\mu) &= \left[\bar{X} - z \frac{\sigma}{\sqrt{n}}, \bar{X} + z \frac{\sigma}{\sqrt{n}} \right] \\ IC_{(1-\alpha) \times 100\%}(\mu) &= \left(\bar{x} - z \frac{\sigma}{\sqrt{n}}, \bar{x} + z \frac{\sigma}{\sqrt{n}} \right) \end{aligned}$$

Observações:

- O intervalo de confiança (numérico) obtido pode ou não conter o verdadeiro valor do parâmetro μ .
- O que se pode garantir é que, para um número muito grande de intervalos de confiança construídos para um dado nível de confiança, $(1 - \alpha) \times 100\%$, se espera que aproximadamente uma proporção $1 - \alpha$ contenha o verdadeiro valor de μ (que continuará, no entanto, a ser desconhecido).
- Quanto menor for o comprimento do intervalo de confiança, maior será a precisão da média (estimativa pontual de μ).
- Se aumentarmos o grau de confiança, com n e σ fixos, aumenta a amplitude do intervalo. Atenção que não faz sentido escolher $1 - \alpha = 1$, pois obtém-se $z = +\infty$. Assim, embora a situação ideal seja ter intervalos de amplitude pequena e com grande confiança, o aumento desta traduz-se numa maior amplitude, pelo que não há grande vantagem em usar uma confiança demasiado elevada.
- Quando n aumenta, mantendo fixos $1 - \alpha$ e σ , a amplitude do intervalo diminui.

Para ilustrar o conceito de intervalo de confiança, representa-se na figura seguinte uma centena de intervalos de confiança a 95% para μ , obtidos a partir de 100 amostras de dimensão 50 cada simuladas da distribuição normal $N(0,1)$. Em média, espera-se que aproximadamente 5 desses intervalos não incluam o verdadeiro valor do parâmetro (que, neste caso, é zero), uma vez que a margem de erro é de 5%. No exemplo apresentado, tem-se exatamente 7 intervalos (representados a tracejado vermelho) que não incluem o valor zero.

```
# 1. Configuração Inicial
set.seed(2025)
n_amostras <- 100      # Número de intervalos/amostras
n <- 50                # Dimensão de cada amostra
sigma <- 1             # Desvio padrão conhecido (variância = 1)
mu_verdadeiro <- 0     # Média da população
confianca <- 0.95      # Nível de confiança de 95%

# Quantil da normal para 95% de confiança
z <- qnorm(1 - (1 - confianca) / 2)

# 2. Definição dos vetores para guardar os limites dos intervalos
limite_inf <- numeric(n_amostras)
limite_sup <- numeric(n_amostras)
medias <- numeric(n_amostras)

# 3. Gerar as amostras e calcular os intervalos
for (i in 1:n_amostras) {
  amostra <- rnorm(n, mean = mu_verdadeiro, sd = sigma)
  media_amostral <- mean(amostra)
  erro_margem <- z * (sigma / sqrt(n))
```

```

        limite_inf[i] <- media_amostral - erro_margem
        limite_sup[i] <- media_amostral + erro_margem
        medias[i] <- media_amostral
    }

# 4. Determinar se o intervalo contém o zero
contem_zero <- (limite_inf <= 0) & (limite_sup >= 0)
cores_linha <- ifelse(contem_zero, "darkgreen", "red")
estilos_linha <- ifelse(contem_zero, 1, 2)

# 5. Construção do Gráfico
par(mar = c(4, 4, 3, 2), bg = "white")


plot(NA,
     xlim = c(min(limite_inf), max(limite_sup)),
     ylim = c(1, n_amostras),
     xlab = "",
     ylab = "N do intervalo (1 a 100)",
     main = "")

abline(v = 0, col = "gray40", lwd = 2, lty = 3)

# Desenhar os 100 intervalos
segments(x0 = limite_inf, y0 = 1:n_amostras,
         x1 = limite_sup, y1 = 1:n_amostras,
         col = cores_linha, lty = estilos_linha, lwd = 1.5)

# Adicionar um ponto para representar a média amostral (estimativa
# pontual) de cada IC
points(x = medias, y = 1:n_amostras, pch = 20, col = cores_linha, cex =
      0.5)

```



Exemplo: Suponha-se que o valor da medição de uma quantidade c , que pode ser afetado por um erro de medição desconhecido, é modelado por uma distribuição normal de média μ e desvio padrão 1. Foram realizadas 10 medições independentes (nas mesmas condições experimentais), tendo-se obtido a amostra: 8.7, 9.1, 10.0, 11.9, 11.7, 8.9, 10.4, 11.2, 10.2, 8.9. Determine um intervalo de confiança a 95% para μ .

Seja X a v.a. que representa o resultado da medição $X \sim N(\mu, 1)$.

1. V.a. fulcral:

$$Z = \frac{\bar{X} - \mu}{\frac{1}{\sqrt{10}}} \sim N(0, 1)$$

2. Quantis de probabilidade: $1 - \alpha = 0.95 \Leftrightarrow \alpha = 0.05$

$$z = \Phi^{-1}\left(1 - \frac{0.05}{2}\right) = \Phi^{-1}(0.975) = 1.96 \text{ (tabela)}$$

3. Inversão da desigualdade:

$$P\left(-z < \frac{\bar{X} - \mu}{\frac{1}{\sqrt{10}}} < z\right) = P\left(\bar{X} - z\frac{1}{\sqrt{10}} < \mu < \bar{X} + z\frac{1}{\sqrt{10}}\right) = 0.95$$

4. Concretização:

$$IA_{95\%}(\mu) = \left] \bar{X} - z\frac{1}{\sqrt{10}}, \bar{X} + z\frac{1}{\sqrt{10}} \right[$$

Como $\bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i = 10.1$, então

$$\begin{aligned} IC_{95\%}(\mu) &= \left] \bar{x} - 1.96\frac{1}{\sqrt{10}}, \bar{x} + 1.96\frac{1}{\sqrt{10}} \right[\\ &= \left] 10.1 - 1.96\frac{1}{\sqrt{10}}, 10.1 + 1.96\frac{1}{\sqrt{10}} \right[\\ &=]9.48, 10.72[\end{aligned}$$

Situação 2. IC para a média de uma população normal, variância desconhecida

Considere-se novamente uma população $X \sim N(\mu, \sigma^2)$, mas agora com σ^2 desconhecida e μ o parâmetro a estimar. Esta é a situação mais realista, mas na qual já não é possível utilizar a v.a. fulcral do ponto anterior (sendo σ desconhecido, então Z não é uma v.a. fulcral). O procedimento lógico é substituir σ por S (desvio padrão amostral) e, nesse caso, obtém a v.a. fulcral


$$\frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}}$$

$$\text{onde } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left[\left(\sum_{i=1}^n X_i^2 \right) - n\bar{X}^2 \right].$$

Neste caso, a distribuição da v.a. fulcral muda e sabe-se que


$$T = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}$$

ou seja, T segue uma distribuição t -Student com $n - 1$ graus de liberdade. O formato da função de densidade de probabilidade da distribuição t -Student é semelhante ao da normal com média 0 (sendo exatamente a $N(0, 1)$ quando o número de graus de liberdade é ∞):



A construção do intervalo aleatório associado a μ segue a mesma lógica do caso anterior:

$$\begin{aligned} P(a < T < b) &= 1 - \alpha \\ \Leftrightarrow P\left(a < \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} < b\right) &= 1 - \alpha \\ \Leftrightarrow P\left(\bar{X} - b \frac{S}{\sqrt{n}} < \mu < \bar{X} - a \frac{S}{\sqrt{n}}\right) &= 1 - \alpha \end{aligned}$$



Considerando $t = F_{t_{n-1}}^{-1}(1 - \frac{\alpha}{2})$:

$$\begin{aligned} IA_{(1-\alpha) \times 100\%}(\mu) &= \left[\bar{X} - t \frac{S}{\sqrt{n}}, \bar{X} + t \frac{S}{\sqrt{n}} \right] \\ IC_{(1-\alpha) \times 100\%}(\mu) &= \left(\bar{x} - t \frac{s}{\sqrt{n}}, \bar{x} + t \frac{s}{\sqrt{n}} \right) \end{aligned}$$

Em R, a função `t.test` permite obter este intervalo de confiança, sendo que os quantis podem ser obtidos com a função `qt(prob, df)`, onde `df` representa o número de graus de liberdade, $n - 1$.

Observações:

- As observações feitas no caso anterior de σ conhecido permanecem válidas, no que diz respeito à interpretação.

- Se $1 - \alpha$ aumentar, com n fixo, a amplitude do intervalo aumenta.
- Se n aumentar, com $1 - \alpha$ fixo, espera-se que a amplitude do intervalo diminua, mas não se pode garantir que isso aconteça sempre, pois s varia de amostra para amostra.

Exemplo: Considere novamente o exemplo do valor da medição de uma quantidade c , que pode ser afetado por um erro de medição desconhecido. Considere agora que esse valor pode ser modelado por uma distribuição normal de média μ e desvio padrão σ . Utilizando a mesma amostra de 10 medições, determine um intervalo de confiança a 95% para μ .

Sendo $X \sim N(\mu, \sigma^2)$:

1. V.a. fulcral:

$$T = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{10}}} \sim t_{n-1}$$

2. Quantis de probabilidade: $1 - \alpha = 0.95 \Leftrightarrow \alpha = 0.05$

$$t = F_{t_9}^{-1}\left(1 - \frac{0.05}{2}\right) = F_{t_9}^{-1}(0.975) = 2.262 \text{ (tabela)}$$

3. Inversão da desigualdade:

$$P\left(-t < \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} < t\right) = 0.95 \Leftrightarrow P\left(\bar{X} - t \frac{S}{\sqrt{10}} < \mu < \bar{X} + t \frac{S}{\sqrt{10}}\right) = 0.95$$

4. Concretização:

$$IA_{95\%}(\mu) = \left] \bar{X} - t \frac{S}{\sqrt{10}}, \bar{X} + t \frac{S}{\sqrt{10}} \right[$$

$$\text{Como } \bar{x} = 10.1 \text{ e } s = \sqrt{\frac{(\sum_{i=1}^{10} x_i^2) - 10 \times \bar{x}^2}{10-1}} = 1.2,$$


$$\begin{aligned} IC_{95\%}(\mu) &= \left] \bar{x} - t \frac{s}{\sqrt{10}}, \bar{x} + t \frac{s}{\sqrt{10}} \right[\\ &= \left] 10.1 - 2.262 \times \frac{1.2}{\sqrt{10}}, 10.1 + 2.262 \times \frac{1.2}{\sqrt{10}} \right[\\ &=]9.24, 10.96[\end{aligned}$$

Situação 3. IC para a variância de uma população normal (valor médio desconhecido)

Considere-se novamente uma população $X \sim N(\mu, \sigma^2)$, em que se pretende estimar σ^2 (com valor médio desconhecido). Neste caso, a v.a. fulcral é dada por:

$$Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

ou seja, Q segue uma distribuição χ^2 (qui-quadrado) com $n - 1$ graus de liberdade. A função de densidade de probabilidade para diferentes graus de liberdade encontra-se representada abaixo:




De notar que, neste caso, a função densidade de probabilidade não é simétrica e só toma valores positivos. Como foi dito anteriormente, existem infinitos pares de valores (a, b) que verificam a condição

$$P(a < Q < b) = 1 - \alpha.$$

Uma vez que a distribuição não é simétrica e é só positiva, não há uma forma gráfica simples de obter uma relação entre a e b , tal que $b - a$ seja mínima. E também não há uma solução analítica explícita. Assim, usa-se, por analogia,

$$a = F_{\chi_{n-1}^2}^{-1}\left(\frac{\alpha}{2}\right) \quad \text{e} \quad b = F_{\chi_{n-1}^2}^{-1}\left(1 - \frac{\alpha}{2}\right)$$



A construção do intervalo aleatório associado a σ^2 segue a mesma lógica dos casos anteriores, sendo que, neste caso, os cálculos são um pouco diferentes:

$$\begin{aligned} P(a < Q < b) &= 1 - \alpha \\ \Leftrightarrow P\left(a < \frac{(n-1)S^2}{\sigma^2} < b\right) &= 1 - \alpha \\ \Leftrightarrow P\left(\frac{a}{(n-1)S^2} < \frac{1}{\sigma^2} < \frac{b}{(n-1)S^2}\right) &= 1 - \alpha \\ \Leftrightarrow P\left(\frac{(n-1)S^2}{b} < \sigma^2 < \frac{(n-1)S^2}{a}\right) &= 1 - \alpha \end{aligned}$$

Considerando $a = F_{\chi_{n-1}^2}^{-1}\left(\frac{\alpha}{2}\right)$ e $b = F_{\chi_{n-1}^2}^{-1}\left(1 - \frac{\alpha}{2}\right)$

$$\begin{aligned} IA_{(1-\alpha) \times 100\%}(\sigma^2) &= \left] \frac{(n-1)S^2}{b}, \frac{(n-1)S^2}{a} \right[\\ IC_{(1-\alpha) \times 100\%}(\sigma^2) &= \left] \frac{(n-1)s^2}{b}, \frac{(n-1)s^2}{a} \right[\end{aligned}$$

Exemplo: Considere-se novamente a v.a. X que representa o resultado da medição, onde $X \sim$

$N(\mu, \sigma^2)$, com μ e σ desconhecidos, e a amostra de dimensão 10 dada anteriormente. Determine um intervalo de confiança a 99% para σ .

1. V.a. fulcral:

$$Q = \frac{9S^2}{\sigma^2} \sim \chi_9^2$$

2. Quantis de probabilidade: $1 - \alpha = 0.99 \Leftrightarrow \alpha = 0.01$

$$a = F_{\chi_9^2}^{-1}\left(\frac{0.01}{2}\right) = F_{\chi_9^2}^{-1}(0.005) = 1.735 \text{ (tabela)}$$

$$b = F_{\chi_9^2}^{-1}\left(1 - \frac{0.01}{2}\right) = F_{\chi_9^2}^{-1}(0.995) = 23.59 \text{ (tabela)}$$

3. Inversão da desigualdade:

$$P\left(a < \frac{9S^2}{\sigma^2} < b\right) = 0.99 \Leftrightarrow P\left(\frac{9S^2}{b} < \sigma^2 < \frac{9S^2}{a}\right) = 0.99$$

4. Concretização:

$$\text{Como } s^2 = \frac{(\sum_{i=1}^{10} x_i^2) - 10 \times \bar{x}^2}{10-1} = 1.44, \text{ então}$$

$$IA_{99\%}(\sigma^2) = \left[\frac{9S^2}{b}, \frac{9S^2}{a} \right[$$

$$IC_{99\%}(\sigma^2) = \left[\frac{9s^2}{b}, \frac{9s^2}{a} \right[= \left[\frac{9 \times 1.44}{23.59}, \frac{9 \times 1.44}{1.735} \right[$$

$$=]0.549, 7.47[$$

$$IC_{99\%}(\sigma) =]\sqrt{0.549}, \sqrt{7.47}[=]0.74, 2.73[$$

Situação 4. IC para uma proporção

Considere-se uma população muito grande ou infinita e p a proporção (desconhecida) de indivíduos/objetos dessa população que pertencem a uma determinada categoria de interesse (peça defeituosa, voto no partido ABC, ter a doença XYZ, ...). Nesta situação, tem-se que $X \sim \text{Bernoulli}(p)$, onde X toma o valor 1 quando pertence à categoria de interesse, com probabilidade p , e o valor 0 quando não pertence, com probabilidade $1 - p$. Para se obter a v.a. fulcral para este caso é necessário utilizar o TLC. Considerando $X_1, X_2, \dots, X_n$ uma a.a. de $\text{Bernoulli}(p)$, tem-se que $\hat{p} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \stackrel{a}{\sim} N\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$. Logo, $\frac{\bar{X}-p}{\sqrt{\frac{p(1-p)}{n}}} \stackrel{a}{\sim} N(0, 1)$. A utilização desta v.a. para a construção do intervalo de confiança obriga à resolução de uma inequação quadrática para a obtenção dos limites do intervalo, levando ao intervalo

$$IA_{(1-\alpha) \times 100\%}(p) = \left[\frac{2n\bar{X} + z^2 \pm z\sqrt{z^2 + 4n\bar{X}(1-\bar{X})}}{2(n+z^2)} \right] \quad (1)$$

onde $z = \Phi^{-1}(1 - \frac{\alpha}{2})$. Este intervalo pode ser obtido em R utilizando a função `prop.test` (que aplica uma correção de continuidade devida à aproximação de uma distribuição discreta por uma distribuição contínua, quando possível).

Dada a complexidade dos cálculos analíticos, é comum utilizar-se o estimador consiste de p , $\bar{X}$, no denominador da v.a. fulcral, ou seja, analiticamente a v.a. fulcral utilizada para a construção de um intervalo de confiança para a proporção p é:

$$\frac{\bar{X} - p}{\sqrt{\frac{\bar{X}(1 - \bar{X})}{n}}} \stackrel{a}{\sim} N(0, 1)$$

Assim,

$$\begin{aligned} P\left(a < \frac{\bar{X} - p}{\sqrt{\frac{\bar{X}(1 - \bar{X})}{n}}} < b\right) &= 1 - \alpha \\ \Leftrightarrow P\left(a\sqrt{\frac{\bar{X}(1 - \bar{X})}{n}} < \bar{X} - p < b\sqrt{\frac{\bar{X}(1 - \bar{X})}{n}}\right) &= 1 - \alpha \\ \Leftrightarrow P\left(\bar{X} - b\sqrt{\frac{\bar{X}(1 - \bar{X})}{n}} < p < \bar{X} - a\sqrt{\frac{\bar{X}(1 - \bar{X})}{n}}\right) &= 1 - \alpha \end{aligned}$$

Considerando $a = -b$ e $z = b = \Phi^{-1}(1 - \frac{\alpha}{2})$,

$$IA_{(1-\alpha) \times 100\%}(p) = \left[\bar{X} - z\sqrt{\frac{\bar{X}(1 - \bar{X})}{n}}, \bar{X} + z\sqrt{\frac{\bar{X}(1 - \bar{X})}{n}} \right] \quad (2)$$

$$IC_{(1-\alpha) \times 100\%}(p) = \left[\bar{x} - z\sqrt{\frac{\bar{x}(1 - \bar{x})}{n}}, \bar{x} + z\sqrt{\frac{\bar{x}(1 - \bar{x})}{n}} \right]$$

Observações:

- Qualquer um dos intervalos aleatórios de confiança apresentados para uma proporção p são IAC's aproximados, sendo que, o último caso (2) é, geralmente, designado de intervalo de confiança assimpótico para p .
- Baseando-se na utilização do TLC, a utilização destes intervalos implica a existência de uma amostra suficientemente grande (em geral, $n > 30$).
- A aproximação de uma distribuição Bernoulli/Binomial pela distribuição normal apresenta alguns problemas quando a proporção se aproxima de 0 ou de 1.
- Numericamente, é possível obter um IC exato (sem aproximação à distribuição normal) para uma proporção p . Em geral, sendo mais conservativo, apresenta intervalos mais amplos, e, por isso, é apenas usado quando a aproximação à distribuição normal não é adequada (n pequeno ou proporção próxima de 0 ou 1). Em R, deve ser utilizada a função `binom.test`.

Exemplo: Considere-se a população de eleitores portugueses. Uma sondagem (aleatória) a 1200 eleitores revelou que 683 tencionam votar no partido ABC. Determine uma estimativa e um IC aproximado a 95% para a proporção de eleitores na população que tencionam votar no partido ABC.

Seja X a v.a. que indica se o eleitor irá votar no partido ABC. Tem-se que $X \sim \text{Bernoulli}(p)$, onde p é a probabilidade de um eleitor votar nesse partido.

Sabe-se que $\hat{p} = \frac{683}{1200} = 0.569$ é uma estimativa para a proporção de eleitores na população que tencionam votar no partido ABC.

Por outro lado, para a obtenção do IC aproximado, tem-se que:

1. V.a. fulcral:

$$\frac{\bar{X} - p}{\sqrt{\frac{\bar{X}(1 - \bar{X})}{1200}}} \stackrel{a}{\sim} N(0, 1)$$

2. Quantis de probabilidade: $1 - \alpha = 0.95 \Leftrightarrow \alpha = 0.05$

$$z = \Phi^{-1}\left(1 - \frac{0.05}{2}\right) = \Phi^{-1}(0.975) = 1.96$$

3. Inversão da desigualdade:

$$P\left(z < \frac{\bar{X} - p}{\sqrt{\frac{\bar{X}(1 - \bar{X})}{1200}}} < z\right) = 0.95 \Leftrightarrow P\left(\bar{X} - z\sqrt{\frac{\bar{X}(1 - \bar{X})}{1200}} < p < \bar{X} + z\sqrt{\frac{\bar{X}(1 - \bar{X})}{1200}}\right) = 0.95$$

4. Concretização:

$$\begin{aligned} IA_{95\%}(p) &= \left[\bar{X} - z\sqrt{\frac{\bar{X}(1 - \bar{X})}{1200}}, \bar{X} + z\sqrt{\frac{\bar{X}(1 - \bar{X})}{1200}} \right] \\ IC_{95\%}(p) &= \left[\bar{x} - z\sqrt{\frac{\bar{x}(1 - \bar{x})}{1200}}, \bar{x} + z\sqrt{\frac{\bar{x}(1 - \bar{x})}{1200}} \right] \\ &= \left[0.569 - 1.96 \times \sqrt{\frac{0.569(1 - 0.569)}{1200}}, 0.569 + 1.96 \times \sqrt{\frac{0.569(1 - 0.569)}{1200}} \right] \\ &=]0.541, 0.597[\end{aligned}$$

Esta informação pode ser lida da forma que é usualmente apresentada nas sondagens divulgadas nos meios de comunicação social: 56.9% dos eleitores tencionam votar no partido ABC com um erro máximo de 2.8% para um nível de confiança de 95% (pois $2.8\% = 1.96 \times \sqrt{\frac{0.569(1-0.569)}{1200}} \times 100\%$).

Em R, o IC aproximado pode ser obtido através da função `prop.test(683, 1200)`. De relembrar que o IC obtido será pela Equação (1) e não pela (2), como calculado analiticamente.

5.3 Testes de hipóteses

Imagine uma máquina de encher pacotes de açúcar, onde o peso de cada pacote deve ser $\approx 6\text{g}$ ($\mu = 6$). Será possível concluir a partir da medição do peso de um certo número de pacotes que a máquina está a encher corretamente?

Imagine um produto de limpeza que indica que a eficácia contra o vírus que pode causar a Covid-19 é de 99.9%. Será que a eficácia é realmente 0.999 ($p = 0.999$)?

Um **teste de hipóteses** é um procedimento estatístico que permite averiguar se os dados sustentam uma **hipótese estatística**, ou seja, uma conjectura sobre uma característica da população.

Existem diferentes tipos de testes de hipóteses, por exemplo:

- Testes sobre os parâmetros das distribuições: **testes paramétricos**;
- Testes sobre a distribuição de onde são provenientes os dados, ou seja, testes que permitem responder à questão de saber se a amostra recolhida se pode considerar, ou não, como proveniente de uma variável aleatória com determinada distribuição conhecida: **testes de ajustamento**.

No caso da hipótese especificar completamente a distribuição, *i.e.*, se corresponder a uma única função de distribuição, diz-se que se trata de uma **hipótese simples**. Caso contrário, diz-se que se trata de uma **hipótese composta**.

Exemplo: Considerando uma amostra proveniente de um modelo paramétrico, como o modelo Binomial($1, p$), em que p é desconhecido, a hipótese $p = 1/2$ é simples, enquanto a hipótese $p > 1/2$ é composta. Noutra situação em que apenas se sabe que a variável é discreta, a hipótese "a distribuição é Geométrica(2)" é simples, e a hipótese "a distribuição é Geométrica" é composta.

Num teste de hipóteses, são consideradas duas hipóteses H_0 vs H_1 :

- H_0 é a **hipótese nula**, ou seja, a hipótese que se pretende testar;
- H_1 é a **hipótese alternativa**, ou seja, a complementar da hipótese nula.

Exemplo: Pretende-se saber se uma certa moeda é equilibrada. Neste caso, está-se perante um modelo Bernoulli(p) $\equiv$ Binomial($1, p$), em que p é a probabilidade de sair "cara" nessa moeda. Quer-se testar a hipótese $p = 1/2$ contra a hipótese $p \neq 1/2$, ou seja, $H_0 : p = 1/2$ vs $H_1 : p \neq 1/2$.

Ao tomar uma decisão com base numa amostra, podemos cometer dois tipos de erros:

	Decisão	
	H_0 verdadeira	H_0 falsa
H_0 verdadeira	Decisão correta!	Erro tipo I $P(\text{rejeitar } H_0 H_0 \text{ verdadeira}) = \alpha$
H_0 falsa	Erro tipo II $P(\text{não rejeitar } H_0 H_0 \text{ falsa}) = \beta$	Decisão correta!

É considerado mais grave cometer um erro de tipo I do que um erro de tipo II. Por exemplo, H_0 : o arguido é inocente

H_1 : o arguido é culpado.

É mais grave concluir que o arguido é culpado quando ele, de facto, é inocente, do que dizer que o indivíduo é inocente quando, de facto, ele é culpado.

A probabilidade de cometer um dos erros está relacionada com a probabilidade de cometer o outro tipo de erro. Assim, quando se pretende diminuir um dos erros, aumenta-se o outro. Por esse motivo, uma abordagem clássica consiste em fixar α e procurar um teste que minimize β . Este procedimento corresponde a privilegiar a hipótese nula em relação à hipótese alternativa, por se considerar mais grave cometer um erro do tipo I do que do tipo II. Dado o modo usual de construção de um teste de hipóteses (não detalhado aqui), a conclusão rejeitar H_0 é uma conclusão "forte", porque o erro que se pode cometer ao rejeitar H_0 está bem controlado (α). Por outro lado, não rejeitar H_0 é uma conclusão "fraca", porque o erro que se pode cometer ao não rejeitar H_0 (β) não está bem controlado. Assim, **nunca** se deve dizer que "se aceita H_0 ". Em vez disso, deve dizer-se que "não se rejeita H_0 " ou, preferencialmente, deve dizer-se que "não há evidência suficiente para rejeitar H_0 ".

Procedimento num teste de hipóteses:

1. **Hipóteses:** Definição de H_0 e H_1 .
2. **Estatística de teste:** Identificação da estatística de teste (T) e da sua distribuição sob H_0 .
3. **Região crítica:** Definição da região crítica (região de rejeição de H_0) com base no nível de significância α (usualmente 0.01, 0.05 ou 0.1). A região crítica (RC) define-se como o conjunto de valores da estatística de teste avaliada sob H_0 que levam à rejeição da hipótese nula, ou seja, para os quais há evidência significativa contra H_0 . Na prática, a região crítica é construída de modo a que $P(T \in RC | H_0 \text{ verdadeira}) = \alpha$. Num teste paramétrico sobre um parâmetro θ , o formato da região crítica depende da hipótese alternativa H_1 :

$H_1 : \theta \neq \theta_0$	$RC = \{t \in \mathbb{R} : t < a \vee t > b\}$ com $a = F_{T H_0 \text{ verd}}^{-1}(\frac{\alpha}{2})$ e $b = F_{T H_0 \text{ verd}}^{-1}(1 - \frac{\alpha}{2})$
$H_1 : \theta > \theta_0$	$RC = \{t \in \mathbb{R} : t > b\}$ com $b = F_{T H_0 \text{ verd}}^{-1}(1 - \alpha)$
$H_1 : \theta < \theta_0$	$RC = \{t \in \mathbb{R} : t < a\}$ com $a = F_{T H_0 \text{ verd}}^{-1}(\alpha)$

4. **Valor observado da estatística de teste:** Cálculo do valor observado da estatística de teste com base na amostra representativa recolhida de forma aleatória.
5. **Decisão:** Tomar uma decisão e interpretá-la no contexto da questão de pesquisa. Se o valor observado cair na região crítica, rejeita-se H_0 ; caso contrário, não se rejeita H_0 .

Em alternativa à definição da região crítica (passo 3), pode-se calcular o **valor de prova do teste (valor-p ou p-value)**, que é a probabilidade de observar um valor para a estatística de teste tão ou mais extremo que o valor observado (correspondendo a um afastamento dos dados em relação a H_0 tão ou ainda maior do que o que foi observado), sob a condição de H_0 ser verdadeira. Neste caso, é efetuado o passo 4 (passando o 3 à frente) e depois é calculado o valor de prova. Quando o valor-p é menor do que o nível de significância α , rejeita-se a hipótese nula H_0 . O valor-p também pode ser interpretado como o maior nível de significância α ao qual não se rejeita H_0 .

Tal como na região crítica, num teste paramétrico, o modo de cálculo do valor-p depende da hipótese alternativa H_1 :

$H_1 : \theta \neq \theta_0$	valor-p = $2 \times \min\{P(T_0 < t_0), P(T_0 > t_0)\}$
$H_1 : \theta > \theta_0$	valor-p = $P(T_0 > t_0)$
$H_1 : \theta < \theta_0$	valor-p = $P(T_0 < t_0)$

Coloca-se agora a questão de como escolher a estatística de teste adequada? Na verdade, num teste sobre parâmetros (testes paramétricos), tipicamente, usa-se o mesmo racional da escolha da v.a. fulcral dos intervalos de confiança. As v.a. fulcrais transformam-se numa estatística de teste quando se substitui o parâmetro populacional em estudo pelo valor postulado em H_0 .

5.3.1 Exemplos de testes paramétricos

Exemplo 1: Teste para o valor esperado de uma distribuição normal com variância conhecida

Seja X a v.a. que representa o peso de um pacote de açúcar. Vamos supor que $X \sim N(\mu, 1)$. A máquina está afinada quando $\mu = 6$. Numa amostra de 25 pacotes (recolhida ao acaso) observou-se $\bar{x} = 6.5$. Queremos avaliar, ao nível de significância de 5%, se a máquina continua afinada.

Hipóteses:

$$H_0: \mu = 6 \text{ vs. } H_1: \mu \neq 6$$

Estatística de teste:

$$Z_0 = \frac{\bar{X} - 6}{\frac{1}{\sqrt{25}}} \stackrel{\text{sob } H_0}{\sim} N(0, 1)$$

Região crítica ao nível de significância de $\alpha = 0.05$:

$$RC = \{z \in \mathbb{R} : z < a \vee z > b\} \quad \text{com } a = \Phi^{-1}(0.05/2) \text{ e } b = \Phi^{-1}(1 - 0.05/2)$$

$$RC = \{z \in \mathbb{R} : z < -b \vee z > b\} \quad \text{com } b = \Phi^{-1}(1 - 0.05/2) = \Phi^{-1}(0.975) = 1.96$$

$$RC =] -\infty, -1.96[\cup] 1.96, +\infty[$$

Valor observado da estatística de teste: Com $\bar{x} = 6.5$, obtém-se:

$$z_0 = \frac{6.5 - 6}{\frac{1}{\sqrt{25}}} = 2.5$$

Decisão: Como $z_0 \in RC$, rejeita-se H_0 . Ou seja, existe evidência (ao nível de significância de 5%) de que a máquina está desafinada.

Em alternativa, poderíamos calcular o valor-p. Como se trata de um teste bilateral ($H_1 : \mu \neq 6.5$),

$$\begin{aligned}\text{valor-p} &= 2 \times \min(P(Z_0 < 2.5), P(Z_0 > 2.5)) \\ &= 2P(Z_0 > 2.5) \\ &= 2 \times (1 - \Phi(2.5)) \\ &= 2 \times (1 - 0.993790) \\ &= 0.01242\end{aligned}$$

Neste caso, pode-se concluir que:

- Rejeita-se H_0 para $\alpha \geq 1.242\%$;
- Não se rejeita H_0 para $\alpha < 1.242\%$.

Assim, a hipótese H_0 é rejeitada para os níveis de significância usuais (n.s.u.) de 5% e 10%, mas não é rejeitada para 1%.

```
library(BSDA)
z.test(x = rep(6.5, 25), mu = 6, sigma.x = 1, conf.level = 0.95,
       alternative = "two.sided") #0 argumento x deve conter os dados
                                observados. Sendo apenas conhecida a média, podemos indicar que temos
                                25 (dimensão da amostra) valores iguais à média.
#One-sample z-Test
#
#data:  rep(6.5, 25)
#z = 2.5, p-value = 0.01242
#alternative hypothesis: true mean is not equal to 6
#95 percent confidence interval:
#6.108007 6.891993
#sample estimates:
#mean of x
#6.5
```

Considerando este mesmo exemplo, verifique-se as alterações nos casos de hipóteses alternativas unilaterais.

1. Se fosse $H_0 : \mu = 6$ (ou $\mu \leq 6$) vs. $H_1 : \mu > 6$, então

Estatística de teste: a mesma

Valor observado da estatística de teste: o mesmo

Região crítica ao nível de significância de $\alpha = 0.05$:

$$RC =]1.645, +\infty[, \quad \text{pois } b = \Phi^{-1}(0.95) = 1.645$$

Decisão: Como o valor observado se encontra dentro da região crítica, a decisão é rejeitar

H_0 .

O cálculo do valor-p neste caso seria:

$$\text{valor-p} = P(Z_0 > 2.5) = 1 - \Phi(2.5) = 1 - 0.993790 = 0.00621$$

Logo,

- Rejeita-se H_0 para $\alpha \geq 0.621\%$ (inclui os n.s.u. de 1%, 5% e 10%);
- Não se rejeita H_0 para $\alpha < 0.621\%$.

```
z.test(x = rep(6.5, 25), mu = 6, sigma.x = 1, conf.level = 0.95,
       alternative = "greater")
#One-sample z-Test
#
#data:  rep(6.5, 25)
#z = 2.5, p-value = 0.00621
#alternative hypothesis: true mean is greater than 6
#95 percent confidence interval:
#6.171029      NA
#sample estimates:
#mean of x
#6.5
```

2. Se fosse $H_0 : \mu = 6$ (ou $\mu \geq 6$) vs. $H_1 : \mu < 6$, então

Estatística de teste: a mesma

Valor observado da estatística de teste: o mesmo

Região crítica ao nível de significância de $\alpha = 0.05$:

$$RC =] -\infty, -1.645[, \quad \text{pois } a = \Phi^{-1}(0.05) = -1.645$$

Decisão: Como $z_0 = 2.5 \notin RC$, não se deve rejeitar H_0 .

O cálculo do valor-p neste caso seria:

$$\text{valor-p} = P(Z_0 < 2.5) = 0.993790$$

Pode-se concluir que:

- Rejeita-se H_0 para $\alpha \geq 99.38\%$;
- Não se rejeita H_0 para $\alpha < 99.38\%$ (inclui todos os n.s.u.).

```
z.test(x = rep(6.5, 25), mu = 6, sigma.x = 1, conf.level = 0.95,
       alternative = "less")
#One-sample z-Test
#
```

```
#data: rep(6.5, 25)
#z = 2.5, p-value = 0.9938
#alternative hypothesis: true mean is less than 6
#95 percent confidence interval:
#NA 6.828971
#sample estimates:
#mean of x
#6.5
```

Exemplo 2: Teste para o valor esperado de uma distribuição normal com variância desconhecida

O valor tabelado para a constante de acidez do ácido orto-hidroxibenzóico é de 2.81. Queremos saber se os valores determinados experimentalmente estão ou não de acordo com o valor tabelado. Seja Y a v.a. que representa um valor da constante determinado experimentalmente e admita-se que $Y \sim N(\mu, \sigma^2)$. Temos as seguintes 5 observações (que podem ser consideradas como obtidas por amostragem aleatória):

$$y_1 = 3.0935 \quad y_2 = 3.0894 \quad y_3 = 3.1111 \quad y_4 = 3.1113 \quad 3.1262$$

para as quais se obtém: $n = 5$, $\bar{y} = 3.1063$, e $s = 0.014946$.

Hipóteses:

$$H_0 : \mu = 2.81 \text{ vs. } H_1 : \mu \neq 2.81$$

Estatística de teste:

$$T_0 = \frac{\bar{Y} - 2.81}{\frac{S}{\sqrt{5}}} \underset{\text{sob } H_0}{\sim} t_{5-1}$$

Região crítica ao nível de significância de $\alpha = 0.01$:

$$RC = \{t \in \mathbb{R} : t < -b \vee t > b\} \quad \text{com } b = F_{t_4}^{-1}(1 - 0.01/2) = F_{t_4}^{-1}(0.995) = 4.604$$

$$RC =] -\infty, -4.604[\cup] 4.604, +\infty[$$

Valor observado da estatística de teste:

$$t_0 = \frac{3.1063 - 2.81}{\frac{0.014946}{\sqrt{5}}} = 44.33$$

Decisão: Como $t_0 \in RC$, há evidência para rejeitar H_0 ao nível de significância de 1%.

Em alternativa, poderíamos calcular o valor-p. Como se trata de um teste bilateral ($H_1 : \mu \neq$

2.81),

$$\begin{aligned}
 \text{valor-p} &= 2 \times \min(P(T_0 < t_0), P(T_0 > t_0)) \\
 &= 2 \times P(T_0 > 44.33) \\
 &= 2 \times (1 - P(T \leq 44.33)) \\
 &= 2 * (1 - \text{pt}(44.33, 4)) \quad (\text{cálculo em R}) \\
 &= 1.548419e - 06
 \end{aligned}$$

Como o valor-p ≈ 0 , então rejeita-se H_0 para todos os níveis de significância, incluindo os usuais.

Em R, a função `t.test` permite efetuar o teste para o valor esperado de uma população com distribuição normal e variância desconhecida.

```

t.test(x= c(3.0935, 3.0894, 3.1111, 3.1113, 3.1262), mu = 2.81, alternative
      = "two.sided")
#           One Sample t-test
#data:      c(3.0935, 3.0894, 3.1111, 3.1113, 3.1262)
#t = 44.33, df = 4, p-value = 1.548e-06
#alternative hypothesis: true mean is not equal to 2.81
#95 percent confidence interval:
#3.087742 3.124858
#sample estimates:
#mean of x
#3.1063

```

Exemplo 3: Teste para a variância de uma distribuição normal (com valor médio desconhecido)

Um fabricante de determinado tipo de baterias afirma que a vida útil dessas baterias tem um desvio padrão de 0.7. Uma amostra de dimensão 5 foi selecionada (obtida por amostragem aleatória) e os tempos de vida foram os seguintes:

$$(2.1, 3.1, 1.5, 3.4, 2.2)$$

para os quais se obtém: $n = 5$, $\bar{x} = 2.46$, $s^2 = 0.603$. Seja X a v.a. que representa o tempo de vida das baterias (em unidades adequadas). Admita que X tem distribuição normal. Será que os dados apresentados mostram evidência, ao nível de significância de 5%, para concluir que se está de acordo com a afirmação do fabricante?

Hipóteses:

$$H_0 : \sigma^2 = 0.7^2 \quad \text{vs} \quad H_1 : \sigma^2 \neq 0.7^2$$

Estatística de teste:

$$Q_0 = \frac{(5-1)S^2}{0.7^2} \stackrel{\text{sob } H_0}{\sim} \chi_{5-1}^2$$

Região crítica ao nível de significância de $\alpha = 0.05$:

$$RC = \{t \in \mathbb{R} : t < a \vee t > b\}$$

onde $a = F_{\chi^4}^{-1}(0.05/2) = F_{\chi^4}^{-1}(0.025) = 0.484$ e $b = F_{\chi^4}^{-1}(1 - 0.05/2) = F_{\chi^4}^{-1}(0.975) = 11.143$.

$$RC = [0, 0.484 \cup]11.143, +\infty[$$

A região crítica neste caso é limitada inferiormente por 0, uma vez que a distribuição χ^2 não toma valores negativos.

Valor observado da estatística de teste:

$$q_0 = \frac{4 \times 0.603}{0.7^2} = 4.922$$

Decisão: Como $q_0 \notin RC$, há evidência para não rejeitar H_0 ao nível de significância de 5%. Ou seja, os dados sustentam a afirmação do fabricante (para $\alpha = 0.05$).

Em alternativa, poderíamos calcular o valor-p. Tratando-se de um teste bilateral:


$$\begin{aligned} \text{valor-p} &= 2 \times \min\{P(Q_0 < 4.922), P(Q_0 > 4.922)\} \\ &= 2 * \min(\text{pchisq}(4.922, \text{df} = 4), 1 - \text{pchisq}(4.922, \text{df} = 4)) \quad (\text{cálculo em R}) \\ &= 0.5908 \end{aligned}$$

Conclui-se que:

- Rejeita-se H_0 para $\alpha \geq 59.08\%$;
- Não se rejeita H_0 para $\alpha < 59.08\%$ (inclui todos os n.s.u.).

Em R, a função `variance.test` do *package* `LearningStats` permite efetuar o teste para a variância de uma população com distribuição normal (com média desconhecida).

```
library(LearningStats)
variance.test(x = c(2.1,3.1,1.5,3.4,2.2), sigma02 = 0.7^2, alternative =
  "two.sided", alpha = 0.05)
#       Test for the variance of a Normal population with unknown mean
#
#H0: sigma^2 = 0.49 units^2
#Ha: sigma^2 != 0.49 units^2
#T = (n - 1) Sc^2 / sigma0^2
#T in X^2_{n-1}
#alpha = 0.05
#T_obs = 4.92245
#RR = [0, 0.48442] U [11.14329, +infinity)
#p-value = 0.5907
```

**Exemplo 4: Teste de hipóteses para uma probabilidade de sucesso**

Uma sondagem (aleatória) a 1200 eleitores revelou que 683 tencionam votar no partido ABC. Entretanto o presidente do partido tinha afirmado "estou convencido que vamos obter mais de 50% dos votos". Fixando $\alpha = 0.01$, será que, em face dos resultados da sondagem, a afirmação é razoável, ou não?

Hipóteses: Podemos testar

$$H_0 : p = 0.5 \quad \text{vs.} \quad H_1 : p > 0.5$$

e, se rejeitarmos a hipótese nula, então a afirmação é corroborada pela sondagem. A opção por estas hipóteses deve-se ao facto de rejeitar a hipótese nula ser uma conclusão mais "forte" do que não rejeitar a hipótese nula.

Estatística de teste:

$$Z_0 = \frac{\bar{X} - 0.5}{\sqrt{\frac{0.5(1-0.5)}{1200}}} \stackrel{\text{sob } H_0}{\sim} N(0, 1)$$

Nota: Neste caso, a estatística de teste baseia-se na v.a. fulcral que leva ao IA da equação (1), ou seja, $\frac{\bar{X} - p}{\sqrt{\frac{p(1-p)}{n}}} \stackrel{a}{\sim} N(0, 1)$, em vez da v.a. fulcral utilizada para a construção analítica do IA de uma proporção, presente na equação (2).

Região crítica ao nível de significância de $\alpha = 0.01$:

$$RC = \{t \in \mathbb{R} : t > b\} \quad \text{com } b = \Phi^{-1}(1 - 0.01) = \Phi^{-1}(0.99) = 2.3263$$

$$RC =]2.3263, +\infty[$$

Valor observado da estatística de teste: Como $\bar{x} = \frac{683}{1200} = 0.569$,

$$z_0 = \frac{0.569 - 0.5}{\sqrt{\frac{0.5(1 - 0.5)}{1200}}} = 4.79$$

Decisão: Como $z_0 \in RC$, há evidência para rejeitar H_0 ao nível de significância de 1%, ou seja, a afirmação do presidente do partido parece ser corroborada pela sondagem.

Em alternativa, calculando o valor-p de um teste unilateral:

$$\begin{aligned}\text{valor-p} &= P(Z_0 > z_0) \\ &= 1 - \Phi(4.79) \\ &\approx 1 - 1 = 0\end{aligned}$$

Como valor-p ≈ 0 , então rejeita-se H_0 para todos os níveis de significância, incluindo os usuais.

Em R, as funções `prop.test` e `binom.test` permitem efetuar o teste para uma proporção. Atenção que nenhuma das opções aplica a estatística de teste apresentada acima, sendo que a aplicada por `prop.test` é equivalente: no caso em estudo, a estatística de teste utilizada em `prop.test`, sem correção de continuidade, corresponde ao quadrado da estatística de teste apresentada acima, sendo a conclusão com base no valor-p equivalente. A função `binom.test` só deve ser utilizada quando n é pequeno ou a proporção é próxima de 0 ou 1, tal como mencionado no caso dos IA.

```
prop.test(x = 683, n = 1200, p = 0.5, alternative = "greater", conf.
  level = 0.99)
#      1-sample proportions test with continuity correction
#
#data:  683 out of 1200, null probability 0.5
#X-squared = 22.688, df = 1, p-value = 9.53e-07
#alternative hypothesis: true p is greater than 0.5
#99 percent confidence interval:
#0.5352556 1.0000000
#sample estimates:
#p
#0.5691667

prop.test(x = 683, n = 1200, p = 0.5, alternative = "greater", conf.
  level = 0.99, correct = FALSE)
#      1-sample proportions test without continuity correction
#
#data:  683 out of 1200, null probability 0.5
#X-squared = 22.963, df = 1, p-value = 8.256e-07
#alternative hypothesis: true p is greater than 0.5
#99 percent confidence interval:
#0.5356743 1.0000000
#sample estimates:
#p
#0.5691667
```

```
#Comparação entre o valor calculado analiticamente e o valor obtido com
prop.test(..., correct = FALSE)

z0 <- ((683/1200-0.5)/sqrt(0.5^2/1200))
z0^2 # = 22.963 (resultado da estatística de teste utilizada em prop.
test)

binom.test(x = 683, n = 1200, p = 0.5, alternative = "greater", conf.
level = 0.99)
#Exact binomial test
#
#data: 683 and 1200
#number of successes = 683, number of trials = 1200,
#p-value = 9.195e-07
#alternative hypothesis: true probability of success is greater than 0.5
#99 percent confidence interval:
#0.5353095 1.0000000
#sample estimates:
#probability of success
#0.5691667
```

5.3.2 Relação entre intervalos de confiança e testes de hipóteses paramétricos bilaterais

Dado um parâmetro desconhecido θ , um IC a $(1 - \alpha) \times 100\%$ para θ :

$$IC_{(1-\alpha) \times 100\%}(\theta) = [t_1, t_2]$$

baseado numa dada amostra $(x_1, x_2, \dots, x_n)$ e obtido a partir de uma certa v.a. fulcral, então, no teste de hipóteses

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_1 : \theta \neq \theta_0,$$

a mesma amostra leva à rejeição de H_0 ao nível de significância α se e só se:

- $\theta_0 \notin [t_1, t_2]$

ou à não rejeição de H_0 se e só se:

- $\theta_0 \in [t_1, t_2]$.

Ou seja, o IC fornece uma região de não rejeição de H_0 . Esta relação entre os intervalos de confiança e os testes de hipóteses apenas é possível de estabelecer no caso de testes bilaterais (hipótese alternativa com $\neq$) e em que a v.a. fulcral e a estatística de teste são da mesma forma.

Fica aqui a nota que também é possível considerar intervalos unilaterais, com um dos extremos infinito. Estes intervalos de confiança unilaterais podem ser relacionados com os testes de hipóteses unilaterais.

5.3.3 Testes de ajustamento

Teste de ajustamento do qui-quadrado (de Pearson)

Até agora, os testes de hipóteses estudados diziam respeito a parâmetros, mas, como foi referido no início, também se podem efetuar testes com hipóteses sobre a própria forma da distribuição de uma dada população. O teste de ajustamento do qui-quadrado de Pearson é um dos testes de ajustamento mais conhecidos, com vasta aplicação quer em variáveis qualitativas, quer quantitativas. O objetivo deste teste é verificar a hipótese de que um conjunto de observações é proveniente de uma determinada distribuição, discreta, contínua, ou outra. Neste caso, procede-se a um agrupamento dos dados em classes, avaliando de seguida se as suas frequências estão de acordo com o modelo probabilístico em teste. As hipóteses a testar são:

H_0 : a amostra provém de uma população com distribuição especificada (ou de uma população pertencente a determinada família de distribuições);

H_1 : a população de onde provém a amostra não segue a distribuição especificada.

O teste de ajustamento de Pearson pode aplicar-se mesmo quando não existe uma completa especificação da distribuição hipotética, sendo, neste caso, necessário estimar os parâmetros.

De salientar que este teste está orientado essencialmente para grandes amostras, sendo, neste caso, bastante sensível na deteção de pequenas diferenças.

Exemplo: O lançamento de um dado 1000 vezes conduziu à seguinte tabela de frequências observadas (o_i):

i	o_i
1	174
2	174
3	154
4	179
5	154
6	165
Total	1000

Será que os dados obtidos sustentam a hipótese de que "o dado é perfeito"?

As hipóteses de interesse podem ser escritas como

$$H_0 : P(X = i) = \frac{1}{6} = p_i^0, i = 1, \dots, 6$$

vs

$$H_1 : \exists i : P(X = i) \neq \frac{1}{6}$$

Quando H_0 é verdadeira, sabe-se calcular:

- a probabilidade de cada valor (ou classe, em geral), que se designa por p_i^0 ;
- o valor esperado para o número de observações em cada classe (frequências esperadas, sob H_0), $E_i = np_i^0$, onde n é a dimensão da amostra (neste caso, $n = 1000$).

i	o_i	p_i^0	$E_i = np_i^0 = 1000p_i^0$
1	174	1/6	166.67
2	174	1/6	166.67
3	154	1/6	166.67
4	179	1/6	166.67
5	154	1/6	166.67
6	165	1/6	166.67
Total	1000	1	≈ 1000

Mesmo quando H_0 é verdadeira, não se está à espera que as colunas o_i e E_i coincidam, mas os valores devem ser próximos se H_0 for verdadeira. Assim, pode-se medir o afastamento entre o_i e E_i para saber até que ponto é razoável que H_0 seja verdadeira. Se o afastamento não for grande, é razoável não se rejeitar H_0 , caso contrário, deve-se rejeitar H_0 .

Pode mostrar-se que, quando H_0 é verdadeira, a estatística que permite medir o afastamento entre o_i e E_i é dada por:

$$Q_0 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \stackrel{a}{\sim} \chi_{k-\beta-1}^2$$

onde k representa o número de classes (no exemplo, $k = 6$) e β representa o número de parâmetros desconhecidos (no exemplo, $\beta = 0$, porque a distribuição não tem parâmetros desconhecidos).

Deve rejeitar-se H_0 se o valor observado de Q_0 for muito elevado, ou seja, a região crítica do teste, para o nível de significância α , é:

$$RC = \{t \in \mathbb{R} : Q_0 > c\}, \quad \text{com } c = F_{\chi_{(k-\beta-1)}^2}^{-1}(1 - \alpha).$$

i	o_i	p_i^0	$E_i = np_i^0 = 1000p_i^0$	$\frac{(o_i - E_i)^2}{E_i}$
1	174	1/6	166.67	0.322
2	174	1/6	166.67	0.322
3	154	1/6	166.67	0.963
4	179	1/6	166.67	0.912
5	154	1/6	166.67	0.963
6	165	1/6	166.67	0.017
Total	1000	1	≈ 1000	3.499 ($=q_0$)

Se fixarmos $\alpha = 0.05$, com $k - \beta - 1 = 6 - 0 - 1 = 5$, obtém-se $c = F_{\chi_5^2}^{-1}(1 - 0.05) = 11.07$. Logo,

$$RC = [11.07, +\infty[$$

Como $q_0 = 3.499 \notin RC$, não há evidência para rejeitar H_0 ao nível de significância de 5%.

Em alternativa,

$$\begin{aligned} \text{valor-p} &= P(Q_0 > 3.499) \\ &= 1 - \text{pchisq}(3.499, 5) \quad (\text{em R}) \\ &= 0.6235 \end{aligned}$$

ou seja, não há evidência para rejeitar H_0 aos níveis de significância usuais.

Em R, a função `chisq.test` permite efetuar o teste de ajustamento do qui-quadrado (de Pearson).

```
chisq.test(x = c(174,174,154,179,154,165), p = rep(1/6, 6))

#Chi-squared test for given probabilities
#
#data:  c(174, 174, 154, 179, 154, 165)
#X-squared = 3.5, df = 5, p-value = 0.6234
```

Observações:

- Antes de se calcular o valor observado da estatística de teste deve averiguar-se se todos os valores de $E_i \geq 1$ e pelo menos 80% dos $E_i \geq 5$. Caso isso não ocorra, é necessário agrupar classes, para evitar enviesamentos (neste caso, um valor inflacionado) na estatística de teste.
- Para formar as classes (e consequentemente a partição de R_X), quando a v.a. X é contínua ou discreta com muitos valores distintos, é usual usar as regras para a construção de histogramas com classes de amplitude constante: considerar k classes equiprováveis com $p_i = 1/k$ sendo $k \leq \frac{n}{5}$.
- Notar que o número total de observações o_i e E_i é igual e igual à dimensão da amostra, isto é, $\sum_{i=1}^k o_i = \sum_{i=1}^k E_i = n$.

Teste de ajustamento ao modelo normal


Para avaliar a normalidade de uma amostra de dados contínuos de dimensão não inferior a 30 pode-se usar o teste de qui-quadrado. Para além da função `chisq.test` mencionada anteriormente, a função `pearson.test` do *package* `nortest` executa o teste do qui-quadrado, agrupando os dados em k classes equiprováveis e efetua, por defeito, a versão da hipótese nula composta (em que os parâmetros também têm de ser estimados).

Exemplo: Pretende-se construir um modelo de simulação das operações de um determinado terminal de transporte de cereais de um porto situado na Europa. Uma das variáveis a considerar no modelo corresponde à diferença entre a data de chegada dos navios provenientes dos EUA e a respetiva data planeada (em dias). Dado que tal diferença é influenciada por muitos fatores aditivos independentes, há razões para supor que se distribui normalmente (TLC). Pretende-se testar essa hipótese tendo como base uma amostra de dados de dimensão 50.

```
library(nortest)
tempos <- c(1.8, -6.6, -7.4, 4.4, -9.0, -2.0, 2.4, -2.8, -6.0, 15.2,
  -11.6, -5.8, 2.2, 4.0, 5.0, 20.6, -1.8, 12.4, -8.9, -2.4, 8.2, 2.2,
  -5.6, 13.2, -0.3, -1.8, -0.6, 2.6, -7.6, -3.4, 7.6, -4.2, -6.0, 5.0,
  18.8, 0.0, 1.4, -10.0, 3.6, -8.4, 1.0, 1.4, -3.8, 0.4, -1.8, -4.0,
  -9.2, 3.2, 0.2, -1.8)
pearson.test(tempos)
#      Pearson chi-square normality test
```



```
#
#data:  tempos
#P = 7.6, p-value = 0.3692
hist(tempos, breaks = 10, probability = TRUE, main = "Histograma dos
      tempos (em dias) entre datas", col = "skyblue", xlab = "Tempos", ylab
      = "Densidade")
curve(dnorm(x, mean = mean(tempos), sd = sd(tempos)), add = TRUE, col =
      "darkgreen", lwd=2)
```



Como valor- $p = 0.3692$, então há evidência para não rejeitar H_0 para níveis de significância inferiores a 36.92%, incluindo os usuais. Ou seja, há evidência para não rejeitar a normalidade dos dados.

No caso de amostras pequenas, o teste de ajustamento de qui-quadrado não deverá ser aplicado. Neste caso, existem opções específicas para o ajustamento ao modelo normal, como é o caso do teste de Shapiro-Wilk (função `shapiro.test`). A grande vantagem que este teste apresenta é precisamente o facto de ser específico para a Normal e, por esse motivo, mais potente do que outros. Além disso, não necessita de especificação prévia de μ ou σ (o que ocorre frequentemente noutros testes de ajustamento específicos para distribuições contínuas).

5.3.4 Intervalos de confiança e testes de hipóteses para os parâmetros de um modelo de regressão linear

No modelo de regressão linear estudado anteriormente, pressupõe-se que as observações y_i provêm de uma v.a. Y_i tal que $Y_i = a + bx_i + \varepsilon_i$, em que os erros ε_i são i.i.d. $N(0, \sigma^2)$, ou seja, $Y_i \sim N(a + bx_i, \sigma^2)$ são independentes. Resulta também deste pressuposto que $E(Y_i) = a + bx_i$. Nestas circunstâncias, é possível mostrar que

$$T_a = \frac{\hat{a} - a}{\sqrt{\left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} \right) \hat{\sigma}^2}} \sim t_{(n-2)}$$

e

$$T_b = \frac{\hat{b} - b}{\sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}}} \sim t_{(n-2)}$$

onde

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \frac{1}{n-2} \left[\left(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2 \right) - \hat{b}^2 \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) \right],$$

e $\hat{Y}_i = \hat{a} + \hat{b}x_i$.

Estes resultados permitem realizar testes de hipóteses e calcular intervalos de confiança relativos a a e b , respetivamente.

O comando `summary(lm(y ~ x))`, para além de apresentar as estimativas de a e b e do coeficiente de determinação r^2 , também apresenta os valores das estatísticas acima para testar $a = 0$ e $b = 0$ e a estimativa s do desvio padrão σ .

Exemplo: Considerando os dados da duração da erupção e do tempo de espera até à erupção seguinte (eruptions e waiting) da base de dados faithful, efetue-se o ajustamento linear de waiting em função de eruptions.

```
data("faithful")
attach(faithful)
modelo <- lm(waiting ~ eruptions, data = faithful)
summary(modelo)
#Call:
#lm(formula = waiting ~ eruptions, data = faithful)
#
#Residuals:
#Min      1Q  Median      3Q      Max
#-12.0796  -4.4831   0.2122   3.9246  15.9719
#
#Coefficients:
#              Estimate Std. Error t value Pr(>|t|)
#(Intercept)  33.4744     1.1549   28.98  <2e-16 ***
#eruptions    10.7296     0.3148   34.09  <2e-16 ***
#---
#Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#
#Residual standard error: 5.914 on 270 degrees of freedom
#Multiple R-squared:  0.8115, Adjusted R-squared:  0.8108
#F-statistic: 1162 on 1 and 270 DF, p-value: < 2.2e-16
#
```

Da análise destes resultados, repare-se que o valor observado de S é 5.914, de T_a é 28.98 e de T_b é 34.09. Ambos os testes de hipóteses aplicados para testar $a = 0$ e $b = 0$ (hipóteses nulas) deram valores-p inferiores a $2e-16$, indicando existir evidência para a rejeição de ambas as hipóteses nulas. O teste para $a = 0$ permite estudar a relevância do termo independente. Quando não há evidência para a rejeição de H_0 , poderá fazer sentido reestimar a reta de regressão linear sem o termo

independente. Já no caso do teste para $b = 0$, este permite estudar a relevância da própria regressão linear. Assim, caso não haja evidência para a rejeição de H_0 , pode-se concluir que há evidência para a não existência de uma associação linear entre x e y , ou seja, não há associação ou a associação não é linear. Este teste costuma designar-se por **teste à significância da regressão** e é de análise fundamental no contexto da regressão linear.

5.4 Resumo das variáveis aleatórias fulcrais/estatísticas de teste para diferentes intervalos de confiança/testes de hipóteses

- **Populações normais** $X \sim N(\mu, \sigma^2)$

- **IC/Teste para μ**

- * com variância conhecida: $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ (R: `z.test` do *package* BSDA)

- * com variância desconhecida: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$ (R: `t.test`)

- **IC/Teste para σ^2** : $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$ (R: `variance.test` do *package* LearningStats
- apenas para o teste de hipóteses)

- **IC/Teste para a proporção p (amostras grandes)** (R: `prop.test` ou `binom.test`):

V.a. fulcral: $\frac{\bar{X} - p}{\sqrt{\frac{\bar{X}(1 - \bar{X})}{n}}} \stackrel{a}{\sim} N(0, 1)$

Estatística de teste: $\frac{\bar{X} - p}{\sqrt{\frac{p(1 - p)}{n}}} \stackrel{a}{\sim} N(0, 1)$

- **Teste de ajustamento (qui-quadrado de Pearson)**: $\sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \sim \chi_{(k-\beta-1)}^2$ (R: `chisq.test`)

- **Testes para a normalidade dos dados**

- **Shapiro-Wilk** (pequenas amostras) (R: `shapiro.test`)

- **Qui-quadrado de Pearson** (grandes amostras) (R: `chisq.test` ou `pearson.test`)